

**ANALISIS KOMPARASI KINERJA LAYER BiGRU DAN
BiLSTM PADA ARSITEKTUR *DEEP SPEECH* (CRNN)
UNTUK PENGENALAN UCAPAN BAHASA INDONESIA**



TUGAS AKHIR

**Diajukan sebagai salah satu syarat untuk mendapatkan
gelar Sarjana Komputer Strata 1**

Oleh:

**Trecya Dewi Kusumaningrum
0102522022**

**PROGRAM STUDI INFORMATIKA
FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS AL-AZHAR INDONESIA
JAKARTA
2026**

ABSTRAK

Teknologi pengenalan ucapan otomatis atau *Automatic Speech Recognition* (ASR) telah menjadi komponen krusial dalam interaksi manusia dan komputer modern. Namun, pengembangan ASR untuk Bahasa Indonesia masih menghadapi tantangan besar karena keterbatasan sumber daya data (*low-resource language*). Penelitian ini bertujuan membandingkan kinerja dua varian lapisan rekuren dua arah, yaitu *Bidirectional Gated Recurrent Unit* (BiGRU) dan *Bidirectional Long Short-Term Memory* (BiLSTM), pada arsitektur hibrida *Convolutional Recurrent Neural Network* (CRNN) untuk pengenalan ucapan Bahasa Indonesia.

Sinyal audio diekstraksi menjadi representasi Mel-Spectrogram sebagai masukan bagi lapisan *Convolutional Neural Network* (CNN), kemudian diteruskan ke tiga lapisan rekuren dua arah dengan ukuran tersembunyi 256. Pelatihan dilakukan secara *end-to-end* menggunakan fungsi kerugian *Connectionist Temporal Classification* (CTC). Data bersumber dari korpus publik Mozilla Common Voice Bahasa Indonesia. Penelitian dilaksanakan melalui tiga tahap eksperimen: Tahap 1 sebagai *baseline* dengan 12.138 data, Tahap 2 dengan penambahan regularisasi *dropout* 0,3, augmentasi audio, dan *beam search decoding*, serta Tahap 3 dengan perluasan dataset menjadi 30.256 data. Pada setiap tahap, kedua arsitektur dilatih menggunakan konfigurasi dan data yang identik agar perbandingan bersifat adil.

Kinerja diukur menggunakan metrik *Word Error Rate* (WER) dan *Character Error Rate* (CER). Hasil pengujian pada *test set* Tahap 3 yang berisi 1.514 data menunjukkan BiLSTM mencapai WER 26,36% dan CER 6,59%, lebih unggul dibandingkan BiGRU yang mencapai WER 28,13% dan CER 7,01%. Keunggulan BiLSTM terjadi secara konsisten pada ketiga tahap eksperimen. Perluasan dataset terbukti menjadi faktor paling dominan, menurunkan WER validasi BiLSTM dari 56,32% pada Tahap 1 menjadi 27,04% pada Tahap 3. Dengan demikian, BiLSTM direkomendasikan apabila akurasi menjadi prioritas utama, sementara ketersediaan data latih berpengaruh jauh lebih besar terhadap kinerja akhir dibandingkan pemilihan varian lapisan rekuren.

Kata Kunci: *Automatic Speech Recognition, CRNN, BiGRU, BiLSTM, CTC Loss, Word Error Rate, Bahasa Indonesia.*

ABSTRACT

Automatic Speech Recognition (ASR) technology has become a crucial component of modern human-computer interaction. However, developing ASR for Indonesian remains challenging due to limited data resources (low-resource language). This study compares the performance of two bidirectional recurrent layer variants, namely Bidirectional Gated Recurrent Unit (BiGRU) and Bidirectional Long Short-Term Memory (BiLSTM), within a hybrid Convolutional Recurrent Neural Network (CRNN) architecture for Indonesian speech recognition.

Audio signals were extracted into Mel-Spectrogram representations as input to a Convolutional Neural Network (CNN) block, followed by three bidirectional recurrent layers with a hidden size of 256. Training was conducted end-to-end using the Connectionist Temporal Classification (CTC) loss function, using the public Mozilla Common Voice Indonesian corpus. The research was carried out in three experimental stages: Stage 1 as a baseline with 12,138 samples, Stage 2 adding dropout regularisation of 0.3, audio augmentation, and beam search decoding, and Stage 3 expanding the dataset to 30,256 samples. In every stage, both architectures were trained under identical configurations and data to ensure a fair comparison.

Performance was measured using Word Error Rate (WER) and Character Error Rate (CER). Evaluation on the Stage 3 test set of 1,514 samples shows that BiLSTM achieved a WER of 26.36% and a CER of 6.59%, outperforming BiGRU which achieved a WER of 28.13% and a CER of 7.01%. The advantage of BiLSTM was consistent across all three stages. Dataset expansion proved to be the most dominant factor, reducing the BiLSTM validation WER from 56.32% in Stage 1 to 27.04% in Stage 3. Accordingly, BiLSTM is recommended when accuracy is the main priority, while the availability of training data influences final performance far more than the choice of recurrent layer variant.

Keywords: *Automatic Speech Recognition, CRNN, BiGRU, BiLSTM, CTC Loss, Word Error Rate, Indonesian.*

DAFTAR ISI

KATA PENGANTAR	v
RIWAYAT HIDUP	vii
ABSTRAK.....	viii
ABSTRACT.....	x
DAFTAR ISI.....	xi
DAFTAR GAMBAR.....	xiv
DAFTAR TABEL.....	xvi
BAB I PENDAHULUAN.....	1
1.1. Latar Belakang	1
1.2. Rumusan Masalah	3
1.3. Tujuan Penelitian	3
1.4. Manfaat Penelitian	4
1.5. Ruang Lingkup.....	4
1.6. Sistematika Penulisan	5
BAB II	7
2.1. Automatic Speech Recognition (ASR).....	7
2.2. Ekstraksi Fitur (Mel-Spectrogram).....	7
2.3. Convolutional Recurrent Neural Network (CRNN).....	13
2.4. Arsitektur Long Short-Term Memory (LSTM).....	14
2.5. Arsitektur Gated Recurrent Unit (GRU)	16
2.6. Recurrent Neural Network Dua Arah (Bidirectional RNN).....	17
2.7. Connectionist Temporal Classification (CTC) Loss	20
2.8. Decoding Keluaran CTC	21
2.8.1. Greedy Decoding	21
2.8.2. Beam Search Decoding.....	21
2.9. Metrik Evaluasi Kinerja (WER dan CER)	22
2.10. Overfitting dan Teknik Penanganannya	23
2.10.1. Regularisasi.....	23
2.10.2. Augmentasi Data.....	23
2.10.3. Penambahan Data Latih	24
2.11. Studi Literatur Terkait	24
BAB III	28

3.1. Analisis Sistem Pengenalan Suara Saat Ini	28
3.2. Analisis Dataset dan Pustaka yang Digunakan	28
3.2.1. Deskripsi dan Spesifikasi Dataset.....	28
3.2.2. Perluasan Dataset untuk Eksperimen Lanjutan	31
3.3. Analisis Jangkauan Suara dan Batasan Sistem.....	32
3.4. Analisis Sistem yang Akan Dibangun.....	33
3.4.1. Deskripsi Kebutuhan Sistem.....	33
3.4.2. Deskripsi Kebutuhan Perangkat Keras	34
3.4.3. Deskripsi Kebutuhan Perangkat Lunak	34
3.4.4. Spesifikasi Parameter Pelatihan Model	35
3.4.5. Dasar Pemilihan Parameter Model	36
3.4.6. Skema Eksperimen Bertahap	39
3.5. Gambaran Umum Sistem yang Akan Dibangun	41
3.5.1. Metode Penelitian / Alur Kerja Sistem	41
3.5.2. Arsitektur Sistem	42
3.5.3. Perbandingan Varian Model RNN.....	44
BAB IV PERANCANGAN DAN IMPLEMENTASI SISTEM	47
4.1. Implementasi Lingkungan Pengembangan.....	47
4.2. Implementasi Ekstraksi Fitur Mel-Spectrogram	50
4.3. Implementasi Arsitektur Model dan Parameter Pelatihan.....	51
4.4. Proses dan Hasil Pelatihan Model	52
4.5. Hasil Pengujian Model pada Data Uji (Test Set)	55
4.6. Analisis Perbandingan Head-to-Head BiGRU dan BiLSTM.....	57
4.7. Tahap 2: Eksperimen dengan Regularisasi, Augmentasi Data, dan Beam Search Decoding.....	60
4.8. Tahap 3: Eksperimen dengan Perluasan Dataset.....	63
4.9. Analisis Perbandingan Keseluruhan Tiga Tahap Eksperimen	74
4.10. Analisis Kompleksitas Model	77
4.11. Validasi Keberulangan Hasil dengan Beberapa Nilai Seed	79
4.12. Uji Ablasi Strategi Decoding	81
4.13. Pembahasan Umum dan Keterbatasan Sistem	82
BAB V PENUTUP	90
5.1. Kesimpulan.....	90
5.2. Saran	92

Daftar Pustaka.....	94
---------------------	----

DAFTAR GAMBAR

Gambar 2.1	Tahapan Pembentukan Mel-Spectrogram: (a) gelombang audio dalam domain waktu, (b) spektrogram hasil STFT, (c) spektrogram setelah konversi ke desibel, (d) Mel-Spectrogram setelah pemetaan ke skala mel
Gambar 2.2	Bank Filter Mel Berbentuk Segitiga, Tersusun Rapat pada Frekuensi Rendah dan Makin Renggang pada Frekuensi Tinggi
Gambar 2.3	Ilustrasi Ukuran Mel-Spectrogram: (a) matriks $80 \times T$, (b) isi satu frame berupa vektor 80 nilai energi
Gambar 2.4	Arsitektur Sel Long Short-Term Memory (LSTM) beserta Formulasi Matematisnya
Gambar 2.5	Arsitektur Gated Recurrent Unit (GRU) beserta Formulasi Matematisnya
Gambar 2.6	Peta Keterhubungan CNN, RNN, LSTM, GRU, BiLSTM, dan BiGRU pada Arsitektur CRNN-CTC
Gambar 3.1	Representasi Fitur Mel-Spectrogram dari Suara Masukan
Gambar 3.2	Flowchart Proses Kerja Sistem
Gambar 3.3	Blok Diagram Arsitektur CRNN-CTC
Gambar 4.1	Visualisasi Ekstraksi Fitur Mel-Spectrogram
Gambar 4.2	Perbandingan Validation Loss Tahap 1 (BiGRU vs BiLSTM)
Gambar 4.3	Perbandingan Final Word Error Rate (WER) Tahap 1
Gambar 4.4	Perbandingan Final Character Error Rate (CER) Tahap 1
Gambar 4.5	Perbandingan Waktu Evaluasi pada 1.215 Data Uji
Gambar 4.6	Perbandingan Validation Loss Tahap 2 (BiGRU vs BiLSTM)
Gambar 4.7	Perbandingan Word Error Rate (WER) Tahap 2
Gambar 4.8	Perbandingan Character Error Rate (CER) Tahap 2
Gambar 4.9	Perbandingan Validation Loss Tahap 3 (BiGRU vs BiLSTM)
Gambar 4.10	Perbandingan Word Error Rate (WER) Tahap 3

Gambar 4.11	Perbandingan Character Error Rate (CER) Tahap 3
Gambar 4.12	Perbandingan Final Test Loss pada Test Set Tahap 3
Gambar 4.13	Perbandingan Final Word Error Rate (WER) pada Test Set Tahap 3
Gambar 4.14	Perbandingan Final Character Error Rate (CER) pada Test Set Tahap 3
Gambar 4.15	Perbandingan Waktu Inferensi Model pada 1.514 Data Uji Tahap 3
Gambar 4.16	Ringkasan Perbandingan WER dan CER pada Tiga Tahap Eksperimen (Test Set)
Gambar 4.17	Keluaran Program Demo Inferensi pada Sembilan Rekaman Suara Pribadi: (a) kalimat dari data latih, (b) kalimat dari data uji, (c) kalimat karangan sendiri

DAFTAR TABEL

Tabel 2.1	Ringkasan Penelitian Terdahulu yang Relevan.....
Tabel 3.1	Perbandingan Ukuran Dataset Sebelum dan Sesudah Perluasan
Tabel 3.2	Spesifikasi Perangkat Keras
Tabel 3.3	Spesifikasi Perangkat Lunak
Tabel 3.4	Dasar Pemilihan Nilai Parameter Pelatihan Model.....
Tabel 3.5	Skema Konfigurasi Tiga Tahap Eksperimen
Tabel 3.6	Perbandingan Arsitektur Layer BiGRU dan BiLSTM.....
Tabel 4.1	Struktur dan Fungsi Modul Program.....
Tabel 4.2	Realisasi Parameter Pelatihan pada Kode Program
Tabel 4.3	Kamus Karakter (Vocabulary) 30 Token Hasil Pembangunan dari Data Latih.....
Tabel 4.4	Ringkasan Hasil Pelatihan Tahap 1 (Metrik Validasi).....
Tabel 4.5	Hasil Evaluasi Tahap 1 pada Data Uji (Test Set).....
Tabel 4.6	Ringkasan Perbedaan Karakteristik LSTM dan GRU beserta Implikasinya
Tabel 4.7	Ringkasan Hasil Tahap 2 (Metrik Validasi).....
Tabel 4.8	Perbandingan Ukuran Dataset Tahap 1/2 dan Tahap 3
Tabel 4.9	Ringkasan Hasil Pelatihan Tahap 3 (Metrik Validasi).....
Tabel 4.10	Hasil Evaluasi Akhir pada Test Set Tahap 3.....
Tabel 4.11	Contoh Perbandingan Teks Ground Truth dan Hasil Prediksi Model BiLSTM pada Data Uji Tahap 3.....
Tabel 4.12	Contoh Perbandingan Teks Ground Truth dan Hasil Prediksi Model BiGRU pada Data Uji Tahap 3
Tabel 4.13	Ringkasan Progres Tiga Tahap Eksperimen (Metrik Test Set).....
Tabel 4.14	Perbandingan Kompleksitas Model BiGRU dan BiLSTM.....
Tabel 4.15	Hasil WER Validasi pada Tiga Nilai Seed (Konfigurasi Tahap 1)..

Tabel 4.16	Hasil Uji Ablasi Strategi Decoding pada Checkpoint Tahap 1 (Data Uji, 1.215 Ucapan)
Tabel 4.17	Hasil Demo Inferensi Model BiLSTM pada Sembilan Rekaman Suara Pribadi (Beam Search Decoding, Lebar 10)
Tabel 4.18	Hasil Demo Inferensi Model BiGRU pada Sembilan Rekaman Suara Pribadi (Beam Search Decoding, Lebar 10)
Tabel 4.19	Rekapitulasi WER dan CER per Kelompok Rekaman pada Demo Inferensi.....

BAB I

PENDAHULUAN

1.1. Latar Belakang

Teknologi interaksi manusia dan komputer (*Human-Computer Interaction*) telah mengalami perkembangan pesat, khususnya dalam pemrosesan sinyal suara. Sistem Pengenalan Ucapan Otomatis atau *Automatic Speech Recognition* (ASR) kini menjadi komponen vital dalam berbagai teknologi, mulai dari asisten virtual, layanan transkripsi otomatis, hingga alat bantu komunikasi bagi penyandang disabilitas (Hannun et al., 2014). Meskipun sistem ASR untuk Bahasa Inggris telah mencapai tingkat akurasi yang tinggi, pengembangan model untuk Bahasa Indonesia masih menghadapi tantangan tersendiri, terutama terkait ketersediaan sumber daya data (*low-resource language*) dan kebutuhan akan arsitektur yang efisien secara komputasi (Ardila et al., 2020; Pratama & Amrullah, 2024).

Secara konvensional, sistem pengenalan ucapan dibangun menggunakan metode statistik seperti *Hidden Markov Model* (HMM). Namun, pendekatan ini mulai ditinggalkan karena kompleksitasnya dalam memodelkan fitur suara yang bervariasi. Seiring kemajuan *Deep Learning*, arsitektur jaringan syaraf tiruan hibrida, khususnya *Convolutional Recurrent Neural Network* (CRNN), telah menjadi standar baru yang efektif (Cakir et al., 2017). Arsitektur CRNN menggabungkan keunggulan *Convolutional Neural Network* (CNN) dalam mengekstraksi fitur visual dari representasi spektral suara (seperti Mel-Spectrogram), dengan kemampuan *Recurrent Neural Network* (RNN) dalam memproses data sekuensial atau urutan waktu (Sari & Putra, 2021).

Dalam implementasi CRNN, komponen RNN memegang peranan krusial untuk mempelajari konteks kalimat. Namun RNN standar memiliki kelemahan *vanishing gradient problem*, dimana model mengalami kesulitan mempelajari ketergantungan pada kalimat yang panjang. Untuk mengatasi hal ini, dikembangkan varian RNN berbasis gerbang (*gated architecture*), yaitu *Long Short-Term Memory* (LSTM) dan *Gated Recurrent Unit* (GRU). LSTM dikenal memiliki kemampuan mengingat konteks jangka panjang yang sangat baik berkat struktur tiga gerbang

(*input*, *output*, *forget*), namun memiliki kompleksitas komputasi yang tinggi (Graves et al., 2006).

Di sisi lain, GRU hadir sebagai penyederhanaan dari LSTM dengan menggabungkan gerbang *forget* dan *input* menjadi satu *update gate*. Secara teoritis, GRU menawarkan efisiensi parameter yang lebih sedikit dan waktu pelatihan yang lebih cepat dibandingkan LSTM (Chung et al., 2014). Beberapa penelitian terbaru menunjukkan bahwa GRU mampu memberikan performa yang kompetitif bahkan lebih unggul dalam kecepatan konvergensi pada berbagai kasus data runtun waktu (Priadinata et al., 2025; Hamayel & Owda, 2021).

Meskipun perbandingan antara LSTM dan GRU telah banyak dilakukan, penelitian yang secara spesifik membandingkan kinerjanya pada arsitektur CRNN untuk pengenalan ucapan Bahasa Indonesia masih terbatas. Sebagian besar penelitian ASR Bahasa Indonesia cenderung berfokus pada implementasi satu jenis algoritma saja, misalnya hanya menggunakan GRU unidirectional (Firmansyah & Bachtiar, 2021) atau fokus pada klasifikasi emosi suara (Aini, 2021), tanpa melakukan komparasi *head-to-head* antara GRU dan LSTM pada arsitektur hibrida yang sama. Padahal, pemilihan layer RNN yang tepat sangat mempengaruhi trade-off antara akurasi model dan efisiensi waktu pelatihan, yang krusial untuk penerapan sistem pada perangkat nyata.

Berdasarkan permasalahan tersebut, penelitian ini bertujuan untuk melakukan analisis perbandingan kinerja antara layer GRU dan LSTM pada arsitektur CRNN. Evaluasi dilakukan menggunakan metode *Connectionist Temporal Classification* (CTC) yang memungkinkan model belajar secara end-to-end tanpa penyelarasan manual (Graves et al., 2006). Penelitian ini menggunakan dataset publik *Mozilla common voice* korpus Bahasa Indonesia untuk mengukur parameter akurasi (*loss*) dan kecepatan komputasi (*training time*), sehingga dapat memberikan rekomendasi empiris mengenai arsitektur terbaik untuk pengembangan sistem ASR Bahasa Indonesia.

1.2. Rumusan Masalah

Berdasarkan Latar Belakang yang telah dipaparkan, maka rumusan masalah dalam penelitian ini adalah:

1. Identifikasi: Bagaimana karakteristik data audio korpus *Mozilla Common Voice* Bahasa Indonesia dan hasil ekstraksi fitur akustik *Mel-Spectrogram* yang diperlukan sebagai masukan bagi model pengenalan ucapan berbasis *Convolutional Recurrent Neural Network* (CRNN)?
2. Desain dan Implementasi: Bagaimana merancang dan mengimplementasikan arsitektur CRNN dengan lapisan rekuren *Bidirectional Gated Recurrent Unit* (BiGRU) dan *Bidirectional Long Short-Term Memory* (BiLSTM) yang diselaraskan menggunakan fungsi kerugian *Connectionist Temporal Classification* (CTC) Loss untuk pengenalan ucapan Bahasa Indonesia?
3. Evaluasi: Bagaimana perbandingan kinerja antara lapisan BiGRU dan BiLSTM pada arsitektur CRNN tersebut, ditinjau dari tingkat akurasi menggunakan metrik *Word Error Rate* (WER) dan *Character Error Rate* (CER), serta efisiensi waktu komputasi pelatihan (*training time*)?

1.3. Tujuan Penelitian

Mengacu pada rumusan masalah yang telah ditetapkan, maka tujuan yang ingin dicapai dalam penelitian ini adalah:

1. Identifikasi: Menganalisis karakteristik dataset audio *Mozilla Common Voice* Bahasa Indonesia serta hasil ekstraksi fitur *Mel-Spectrogram* yang sesuai untuk digunakan sebagai masukan model pengenalan ucapan berbasis CRNN.
2. Desain dan Implementasi: Merancang dan mengimplementasikan arsitektur *Convolutional Recurrent Neural Network* (CRNN) dengan lapisan rekuren BiGRU dan BiLSTM yang diselaraskan menggunakan fungsi *Connectionist Temporal Classification* (CTC) Loss untuk pengenalan ucapan Bahasa Indonesia.
3. Evaluasi: Mengukur dan membandingkan kinerja lapisan BiGRU dan BiLSTM pada arsitektur CRNN berdasarkan metrik evaluasi *Word Error*

Rate (WER), *Character Error Rate* (CER), serta efisiensi waktu komputasi pelatihan (*training time*) guna memberikan rekomendasi empiris bagi pengembangan sistem *Automatic Speech Recognition* (ASR) Bahasa Indonesia.

1.4. **Manfaat Penelitian**

Penelitian ini diharapkan dapat memberikan manfaat yang signifikan, baik secara teoretis maupun praktis, antara lain:

1. Bagi akademisi dan Peneliti: Memperkaya literatur dan referensi ilmiah mengenai perbandingan kinerja secara *head-to-head* antara algoritma *Gated Recurrent Unit* (GRU) dan *Long Short-Term Memory* (LSTM) pada arsitektur hibrida CRNN, secara spesifik untuk kasus pengenalan ucapan (*Speech Recognition*) Bahasa Indonesia.
2. Bagi Pengembang Perangkat Lunak (Praktisi): Memberikan panduan empiris dalam memilih arsitektur *Recurrent Neural Network* yang paling efisien, terutama ketika mengembangkan sistem ASR berbasis kecerdasan buatan (*Artificial Intelligence*) pada perangkat keras dengan sumber daya komputasi dan memori yang terbatas (*edge computing* atau implementasi lokal).
3. Bagi Penulis: Mengimplementasikan ilmu yang telah dipelajari selama masa perkuliahan, khususnya di bidang *Machine Learning* dan *Deep Learning*, serta sebagai syarat akademis untuk menyelesaikan studi tingkat strata 1 (S1) pada program studi Informatika.

1.5. **Ruang Lingkup**

Agar penelitian ini tetap terfokus, mendalam, serta tidak menyimpang dari tujuan awal, maka ditetapkan ruang lingkup sebagai berikut:

1. Dataset: Data latih atau data uji yang digunakan terbatas pada dataset audio Bahasa Indonesia dari korpus Mozilla Common Voice (menggunakan file *train.tsv* dan folder *clips*).

2. **Arsitektur Model:** Model jaringan syaraf tiruan yang dibangun berfokus pada arsitektus *Convolutional Recurrent Neural Network (CRNN) end-to-end*.
3. **Fokus Arsitektur Rekuren:** Komparasi difokuskan pada varian dua arah (Bidirectional) dari layer rekuren, yaitu Bidirectional Gated Recurrent Unit (BiGRU) dan Bidirectional Long Short-Term Memory (BiLSTM), tanpa melibatkan varian Unidirectional. Metode Penyelarasan: Proses pembelajaran sekuensial antara audio dan teks menggunakan fungsi kerugian *Connectionist Temporal Classification (CTC) Loss*.
4. **Ekstraksi Fitur:** Sinyal audio mentah diproses menjadi representasi visual menggunakan transformasi *Mel-Spectrogram* dengan frekuensi sampling 16.000 Hz.
5. **Lingkungan pengujian:** Eksperimen pelatihan model dilakukan secara lokal menggunakan bahasa pemrograman Python, *library* PyTorch, dan editor Visual Studio Code, untuk mendapatkan data waktu komputasi (*training time*) riil pada perangkat keras laptop/PC
6. **Metrik Evaluasi:** Tolak ukur yang digunakan untuk membandingkan kinerja adalah *Loss*, *Word Error Rate (WER)*, *Character Error Rate (CER)*, dan waktu komputasi per *epoch*

1.6. **Sistematika Penulisan**

Untuk memberikan gambaran yang jelas dan terstruktur mengenai penyusunan laporan Tugas Akhir ini, sistematika penulisan dibagi menjadi lima bab dengan uraian sebagai berikut:

BAB I : PENDAHULUAN

Bab ini menguraikan gambaran umum penelitian yang meliputi latar belakang masalah mengenai sistem pengenalan ucapan Bahasa Indonesia dan perbandingan arsitektur rekuren, rumusan masalah, tujuan penelitian, manfaat penelitian, ruang lingkup (batasan masalah), serta sistematika penulisan laporan.

BAB II : LANDASAN TEORI

Bab ini berisi tinjauan pustaka dasar-dasar teori yang relevan untuk mendukung penelitian. Materi yang dibahas meliputi konsep *Automatic Speech Recognition* (ASR), pemrosesan sinyal suara menjadi *Mel-Spectrogram*, arsitektur jaringan syaraf tiruan *Convolutional Neural Network* (CNN), *Recurrent Neural Network* (RNN) beserta variannya (GRU dan LSTM), fungsi kerugian *Connectionist Temporal Classification* (CTC), serta metrik evaluasi kinerja model.

BAB III : METODOLOGI PENELITIAN

Bab ini menjelaskan analisis kebutuhan dan perancangan sistem yang akan dibangun. Pembahasan meliputi deskripsi kebutuhan perangkat keras dan perangkat lunak untuk lingkungan pengembangan lokal, analisis dataset (Mozilla Common Voice), tahapan pra-pemrosesan data (*preprocessing*), hingga perancangan arsitektur *Convolutional Recurrent Network* (CRN) hibrida secara detail.

BAB IV : PERANCANGAN DAN IMPLEMENTASI SISTEM

Bab ini memaparkan implementasi dari rancangan arsitektur ke dalam kode program, serta memuat hasil pengujian sistem. Bagian ini akan menyajikan proses pelatihan (*training*) model, visualisasi hasil eksperimen, hingga analisis komparatif secara head-to-head antara performa layer BiGRU dan BiLSTM ditinjau dari akurasi pengenalan teks (WER/CER) dan efisiensi waktu komputasi

BAB V : PENUTUP

Bab ini merupakan bagian akhir laporan yang berisi kesimpulan komprehensif dari hasil analisis pengujian untuk menjawab rumusan masalah dan tujuan penelitian. Selain itu, bab ini juga memberikan saran-saran konstruktif bagi pengembangan sistem ASR Bahasa Indonesia maupun untuk penelitian selanjutnya di masa mendatang.

BAB II

LANDASAN TEORI

2.1. Automatic Speech Recognition (ASR)

Automatic Speech Recognition (ASR) adalah teknologi yang memungkinkan mesin untuk mengenali dan mengonversi sinyal akustik ucapan manusia menjadi teks tertulis. Sistem ASR modern, seperti arsitektur *Deep Speech*, telah menjadi standar dalam membangun sistem pengenalan ucapan *end-to-end* yang adaptif (Hannun et al., 2014). Namun, dalam pengembangannya, ASR Bahasa Indonesia masih dikategorikan sebagai bahasa dengan sumber daya terbatas (*low-resource language*) karena kurangnya ketersediaan korpus suara yang masif (Pratama & Amrullah, 2024). Untuk mengatasi hal ini, penggunaan dataset publik dengan skala besar seperti korpus multibahasa Mozilla Common Voice menjadi solusi yang sangat vital untuk melatih model kecerdasan buatan (Ardila et al., 2020).

Perkembangan sistem ASR modern secara umum telah bergeser menuju pendekatan *end-to-end* berbasis pembelajaran mendalam, sebagaimana dirangkum dalam survei komprehensif oleh Prabhavalkar et al. (2024).

2.2. Ekstraksi Fitur (Mel-Spectrogram)

Sebelum diproses oleh model *Deep Learning*, sinyal audio mentah harus diubah menjadi bentuk representasi visual. Penelitian membuktikan bahwa penggunaan *Mel-Spectrogram* seringkali lebih kaya akan informasi frekuensi dan lebih optimal saat diproses oleh jaringan syaraf tiruan dibandingkan metode konvensional seperti *Mel-Frequency Cepstral Coefficients* (MFCC) (Nugraha & Hidayat, 2022). *Mel-Spectrogram* bekerja dengan meniru sensitivitas telinga manusia terhadap rentang frekuensi tertentu, sehingga fitur visual yang dihasilkan sangat representatif untuk menangkap karakteristik fonem (Nugraha & Hidayat, 2022).

Kajian perbandingan pada bahasa dengan sumber daya terbatas turut menunjukkan bahwa representasi berbasis spektrogram efektif ketika dipadukan dengan arsitektur CNN-LSTM (Telmam et al., 2024).

Pernyataan tersebut perlu diuraikan lebih lanjut agar dasarnya jelas. MFCC dan *Mel-Spectrogram* sebenarnya berasal dari rangkaian proses yang sama sampai tahap pemetaan ke skala mel; perbedaannya hanya terletak pada satu langkah tambahan di bagian akhir. Pada MFCC, keluaran bank filter mel masih dilewatkan melalui *Discrete Cosine Transform* (DCT) yang memampatkan puluhan nilai energi menjadi sekitar 13 sampai 39 koefisien saja. Pemampatan tersebut dirancang pada era pengenalan ucapan berbasis *Hidden Markov Model*, ketika model statistik yang digunakan mensyaratkan fitur berdimensi kecil dan antar-dimensinya tidak saling berkorelasi. Konsekuensinya, sebagian informasi rinci mengenai bentuk spektrum, termasuk pola harmonik pita suara, ikut hilang pada proses tersebut.

Pada model pembelajaran mendalam, syarat itu tidak lagi berlaku. Lapisan konvolusi justru bekerja dengan memanfaatkan keterkaitan antar-pita frekuensi yang berdekatan, sehingga fitur yang belum dipampatkan seperti *Mel-Spectrogram* lebih menguntungkan dibandingkan fitur yang sudah melewati DCT. Dalam pengertian inilah *Mel-Spectrogram* disebut lebih sederhana: rangkaian pembentukannya berhenti satu langkah lebih awal, tanpa DCT dan tanpa *cepstral liftering*, meskipun dimensi keluarannya justru lebih besar. Perlu dicatat bahwa keunggulan ini tidak bersifat mutlak. Sebagian penelitian pengenalan ucapan Bahasa Indonesia masih memilih MFCC dan memperoleh hasil yang baik (Endah et al., 2025), sehingga pemilihan fitur tetap bergantung pada arsitektur dan skala data yang digunakan.

Adapun alasan tidak menggunakan gelombang audio mentah (*raw waveform*) secara langsung adalah pertimbangan panjang urutan dan kebutuhan data. Audio berdurasi satu detik pada laju cuplik 16.000 Hz terdiri atas 16.000 nilai amplitudo, sedangkan representasi *Mel-Spectrogram* hanya menghasilkan 100 frame untuk durasi yang sama, atau sekitar 160 kali lebih pendek. Model yang belajar langsung dari gelombang mentah harus menemukan sendiri penyaring frekuensi yang pada *Mel-Spectrogram* sudah tersedia sejak awal, dan hal tersebut umumnya memerlukan data latih dalam skala ribuan jam. Dengan ketersediaan data yang terbatas pada penelitian ini, penggunaan fitur yang sudah membawa pengetahuan mengenai sifat pendengaran manusia merupakan pilihan yang lebih realistis.

Proses pembentukan Mel-Spectrogram dari sinyal audio berlangsung melalui empat tahap berurutan (Roberts, 2020), sebagaimana diilustrasikan pada Gambar 2.1.


Tahap pertama, representasi sinyal dalam domain waktu. Suara pada dasarnya adalah perubahan tekanan udara terhadap waktu. Perubahan tersebut dicuplik (*sampling*) pada laju tertentu — dalam penelitian ini 16.000 sampel per detik — sehingga menghasilkan deretan angka yang merepresentasikan amplitudo sinyal secara digital.

Tahap kedua, transformasi ke domain frekuensi. Sinyal dipotong menjadi segmen-segmen pendek yang saling bertumpang tindih (*overlapping window*), lalu setiap segmen ditransformasi menggunakan *Fast Fourier Transform* (FFT) untuk memperoleh kandungan frekuensinya. Rangkaian hasil transformasi disusun berdampingan menurut waktu dan membentuk spektrogram, yaitu representasi dua dimensi dengan sumbu horizontal waktu dan sumbu vertikal frekuensi. Pada penelitian ini setiap jendela berdurasi 25 ms (400 sampel) dengan pergeseran 10 ms (160 sampel), sehingga satu detik audio menghasilkan 100 *frame*.


Tahap ketiga, konversi amplitudo ke desibel. Pendengaran manusia menanggapi intensitas suara secara logaritmik, bukan linear. Karena itu nilai energi pada spektrogram dikonversi ke satuan desibel (dB). Konversi ini memampatkan rentang nilai yang sangat lebar menjadi skala yang lebih seragam, sehingga pola frekuensi berenergi rendah — yang justru banyak membawa informasi fonetis — tetap terlihat jelas. Sebagai perbandingan, panel (b) pada Gambar 2.1 tampak hampir seluruhnya gelap karena rentang energi pada skala linear sangat lebar, sedangkan panel (c) memperlihatkan pola yang jauh lebih informatif setelah konversi desibel diterapkan.

Tahap keempat, pemetaan sumbu frekuensi ke skala mel. Telinga manusia lebih peka membedakan perbedaan frekuensi pada rentang rendah dibandingkan rentang tinggi. Skala mel merepresentasikan sifat tersebut melalui hubungan $m = 2595 \cdot \log_{10}(1 + f / 700)$, dengan f adalah frekuensi dalam Hz dan m frekuensi dalam mel. Sumbu frekuensi spektrogram kemudian dipetakan menggunakan sekumpulan filter segitiga yang tersusun rapat pada frekuensi rendah

dan makin renggang pada frekuensi tinggi, sebagaimana ditunjukkan pada Gambar 2.2. Hasil akhirnya adalah Mel-Spectrogram, representasi yang lebih ringkas dan lebih sesuai dengan persepsi pendengaran manusia, sehingga banyak digunakan sebagai masukan sistem pengenalan ucapan berbasis pembelajaran mendalam (Hannun et al., 2014).




Gambar 2.1 Tahapan Pembentukan Mel-Spectrogram: (a) gelombang audio dalam domain waktu, (b) spektrogram hasil STFT, (c) spektrogram setelah konversi ke desibel, (d) Mel-Spectrogram setelah pemetaan ke skala mel



Gambar 2.2 Bank Filter Mel Berbentuk Segitiga, Tersusun Rapat pada Frekuensi Rendah dan Makin Renggang pada Frekuensi Tinggi

Salah satu parameter utama dalam ekstraksi Mel-Spectrogram adalah jumlah filter mel (n_mels), yaitu banyaknya pita frekuensi yang digunakan untuk meringkas spektrum suara pada setiap *frame*. Rentang frekuensi sinyal dibagi menjadi sejumlah pita menurut skala mel, sehingga setiap *frame* audio terwakili oleh sebuah vektor berdimensi n_mels yang memuat energi tiap pita. Nilai n_mels menentukan resolusi frekuensi fitur: semakin besar nilainya semakin rinci informasi spektral yang dipertahankan, namun dimensi masukan dan beban komputasi ikut membesar. Sistem pengenalan ucapan modern umumnya menggunakan 64 sampai 80 filter mel (Hannun et al., 2014).

Untuk memberi gambaran yang lebih konkret, Gambar 2.3 menyajikan ilustrasi ukuran matriks *Mel-Spectrogram* beserta makna angka 80 tersebut.



Gambar 2.3 *Ilustrasi Ukuran Mel-Spectrogram: (a) matriks 80 x T, (b) isi satu frame berupa vektor 80 nilai energi*

Panel (a) pada Gambar 2.3 memperlihatkan bahwa *Mel-Spectrogram* pada dasarnya adalah sebuah matriks dua dimensi berukuran 80 x T. Angka 80 pada sumbu tegak bukan menyatakan satuan frekuensi dalam Hz, melainkan banyaknya pita (filter) mel yang digunakan untuk meringkas seluruh rentang frekuensi 0 sampai 8.000 Hz. Rentang tersebut dibagi menjadi 80 pita menurut skala mel, dengan pita pada frekuensi rendah dibuat sempit dan rapat sedangkan pita pada frekuensi tinggi dibuat lebih lebar. Adapun T pada sumbu mendatar adalah banyaknya frame, yang bergantung pada durasi rekaman: dengan *hop length* 10 ms, audio berdurasi satu detik menghasilkan 100 frame dan rekaman berdurasi lima detik menghasilkan sekitar 500 frame.

Panel (b) memperlihatkan isi satu frame, yaitu sebuah vektor berisi 80 angka yang masing-masing menyatakan besar energi pada satu pita mel dalam potongan waktu 25 ms tersebut. Dengan demikian keseluruhan rekaman diwakili oleh deretan vektor berdimensi 80 yang tersusun menurut waktu, dan deretan inilah yang menjadi masukan bagi blok CNN. Pemilihan angka 80 merupakan kompromi. Nilai yang lebih kecil, misalnya 40, membuat setiap pita menjadi terlalu lebar sehingga perbedaan halus antar-fonem sulit dibedakan. Sebaliknya nilai yang lebih besar, misalnya 128, memperbesar dimensi masukan dan beban komputasi tanpa memberi tambahan informasi yang sepadan, karena resolusi frekuensi sinyal itu sendiri sudah dibatasi oleh ukuran jendela FFT sebesar 400 sampel.

2.3. Convolutional Recurrent Neural Network (CRNN)

Pendekatan konvensional dalam ASR mulai digantikan oleh arsitektur hibrida *Convolutional Recurrent Neural Network* (CRNN). Arsitektur ini menggabungkan keunggulan ekstraksi fitur spasial dari gambar menggunakan jaringan konvolusional dan pemodelan sekuensial menggunakan jaringan rekuren, menjadikannya standar yang sangat efektif untuk memproses data audio polifonik dan kompleks (Cakir et al., 2017).

Analisis komparatif terhadap model-model pembelajaran mendalam untuk data sekuensial, mencakup CNN, RNN, LSTM, dan GRU, memberikan dasar pemilihan arsitektur yang sesuai dengan karakteristik data (Shiri et al., 2024).

Secara lebih rinci, alur kerja CRNN pada pengenalan ucapan berlangsung dalam tiga tahap yang berurutan. Pertama, citra Mel-Spectrogram berukuran (tinggi x lebar) dilewatkan melalui beberapa lapisan konvolusi dan pooling, menghasilkan peta fitur (feature map) yang memadatkan informasi frekuensi namun mempertahankan dimensi waktu. Kedua, peta fitur tersebut diubah bentuknya (reshape) menjadi sebuah urutan vektor, di mana setiap kolom pada sumbu waktu diperlakukan sebagai satu langkah waktu (time step) yang berisi vektor fitur. Ketiga, urutan vektor ini menjadi masukan bagi lapisan rekuren dua arah, yang memodelkan keterkaitan antar langkah waktu dari kedua arah sebelum diteruskan ke lapisan keluaran.

Keunggulan utama CRNN dibandingkan pendekatan berbasis CNN murni terletak pada kemampuannya memodelkan konteks temporal. Pada ucapan, satu fonem tidak berdiri sendiri melainkan dipengaruhi oleh fonem sebelum dan sesudahnya (koartikulasi). Lapisan rekuren dua arah menangkap ketergantungan ini, sementara CNN di bagian depan memastikan ciri akustik lokal terekstraksi terlebih dahulu, sehingga keduanya saling melengkapi.

Perbedaan antara CNN dan CRNN dapat diringkas sebagai berikut. CNN murni bekerja dengan jendela pandang (*receptive field*) yang terbatas: setiap neuron hanya melihat wilayah kecil di sekitarnya, dan wilayah tersebut baru melebar secara bertahap seiring bertambahnya lapisan. Akibatnya CNN unggul dalam mengenali pola lokal, misalnya bentuk formant sebuah vokal pada rentang beberapa puluh milidetik, tetapi tidak memiliki mekanisme untuk mengingat apa yang terjadi jauh

sebelumnya pada rekaman yang sama. CRNN menambahkan lapisan rekuren di belakang blok CNN, sehingga keluaran pada setiap langkah waktu tidak hanya bergantung pada potongan sinyal di sekitarnya, tetapi juga pada rangkuman seluruh langkah waktu sebelum dan sesudahnya. Singkatnya, CNN menangani dimensi frekuensi dan pola lokal, sedangkan lapisan rekuren menangani dimensi waktu dan konteks panjang.

Sifat rekuren pada arsitektur ini berada sepenuhnya di dalam blok RNN, bukan pada blok CNN. Rekurensi terjadi ketika *hidden state* hasil perhitungan langkah waktu ke- t diumpankan kembali sebagai masukan bagi perhitungan langkah waktu ke- $(t+1)$ pada lapisan yang sama. Blok CNN tidak memiliki umpan balik semacam itu; setiap posisi dihitung secara mandiri sehingga dapat diproses serentak. Karena lapisan rekuren pada penelitian ini bersifat dua arah, umpan balik tersebut berjalan dua kali, yaitu sekali dari awal ke akhir rekaman dan sekali dari akhir ke awal, lalu kedua hasilnya digabungkan. Posisi setiap komponen tersebut di dalam keseluruhan arsitektur ditunjukkan pada peta keterhubungan di Gambar 2.6.

1. **Convolutional Neural Network (CNN):** Berfungsi sebagai *front-end* untuk mengekstraksi pola-pola visual (fitur spektral) dari input *Mel-Spectrogram*. CNN telah terbukti handal dalam pemrosesan dan klasifikasi sinyal suara berbahasa Indonesia (Aini, 2021).
2. **Recurrent Neural Network (RNN):** Menerima fitur dari CNN dan memodelkan urutan waktu (*temporal sequence*). Untuk memaksimalkan performa, lapisan RNN sering diimplementasikan dalam bentuk *Bidirectional* (dua arah). Pendekatan *Bidirectional* memungkinkan model untuk membaca konteks informasi dari masa lalu dan masa depan secara bersamaan, sehingga analisis sekuensial menjadi jauh lebih akurat (Sari & Putra, 2021).

2.4. Arsitektur Long Short-Term Memory (LSTM)


LSTM adalah arsitektur memori rekuren yang dirancang secara khusus untuk mengatasi masalah *vanishing gradient* pada jaringan RNN standar. Dengan arsitektur ini, model mampu mengingat informasi dalam jangka waktu yang panjang melalui struktur tiga gerbang utama: *Input Gate*, *Forget Gate*, dan *Output Gate* (Graves et al., 2006). Meskipun LSTM terbukti sangat tangguh dalam

pemodelan deret waktu, kompleksitas matematis dari ketiga gerbang tersebut menuntut penggunaan parameter yang sangat besar, sehingga beban komputasinya menjadi tinggi (Priadinata et al., 2025).

Secara matematis, pada setiap langkah waktu t , sel LSTM memperbarui kondisinya melalui tiga gerbang yang masing-masing menggunakan fungsi aktivasi sigmoid untuk menghasilkan nilai antara 0 dan 1. Forget gate menentukan seberapa banyak informasi lama yang dipertahankan, input gate menentukan informasi baru yang disimpan, dan output gate menentukan bagian kondisi sel yang diteruskan sebagai keluaran. Arsitektur sel LSTM beserta formulasi matematisnya secara lengkap ditunjukkan pada Gambar 2.4.

Di mana x_t adalah masukan pada langkah waktu t , h_{t-1} adalah keluaran (hidden state) sebelumnya, C_t adalah kondisi sel (cell state) yang berperan sebagai memori jangka panjang, $\tilde{C}_t$ adalah kandidat kondisi sel, W dan b adalah bobot dan bias yang dipelajari, σ adalah fungsi sigmoid, dan tanda $\odot$ menyatakan perkalian elemen per elemen (Hadamard). Keberadaan cell state C_t yang mengalir dengan sedikit gangguan inilah yang memungkinkan LSTM mempertahankan informasi jangka panjang dan mengatasi masalah vanishing gradient.

Dalam penelitian ini, LSTM tidak digunakan dalam bentuk satu arah, melainkan dalam bentuk dua arah (Bidirectional LSTM atau BiLSTM), sebagaimana dijelaskan pada Sub-bab 2.6.



Gambar 2.4 Arsitektur Sel Long Short-Term Memory (LSTM) beserta Formulasi Matematisnya

Sumber: Kizito et al. (2021)

2.5. Arsitektur Gated Recurrent Unit (GRU)


GRU diperkenalkan sebagai alternatif penyederhanaan dari LSTM. GRU menggabungkan *forget gate* dan *input gate* ke dalam satu gerbang tunggal yang disebut *update gate* (Chung et al., 2014). Secara teoritis dan empiris, GRU memiliki jumlah parameter yang lebih sedikit, sehingga menawarkan waktu pelatihan yang lebih cepat dan efisiensi memori yang lebih baik dibandingkan dengan LSTM pada pemrosesan sekuensial (Hamayel & Owda, 2021). Penelitian terbaru tahun 2025 juga memvalidasi bahwa dalam berbagai kasus peramalan deret waktu, GRU unggul dalam kecepatan konvergensi tanpa harus mengorbankan akurasi yang terlalu besar (Priadinata et al., 2025). Pada kasus pengenalan ucapan bahasa Indonesia, GRU sebelumnya pernah diimplementasikan dalam bentuk *Unidirectional* (Firmansyah & Bachtiar, 2021), sehingga komparasi kinerjanya dalam bentuk *Bidirectional* pada CRNN menjadi pengembangan yang sangat relevan.

Secara matematis, GRU menyederhanakan LSTM menjadi hanya dua gerbang, yaitu *update gate* (z_t) dan *reset gate* (r_t), serta menghilangkan cell state terpisah sehingga memori sepenuhnya diwakili oleh hidden state. Update gate mengatur seberapa banyak informasi lama dipertahankan dibandingkan informasi

baru, sedangkan reset gate mengatur seberapa banyak informasi masa lalu diabaikan saat menghitung kandidat keadaan baru. Arsitektur GRU beserta formulasi matematisnya ditunjukkan pada Gambar 2.5.

Dengan hanya dua gerbang dan satu jalur memori, GRU memiliki jumlah parameter yang lebih sedikit dibandingkan LSTM (tiga gerbang dan dua jalur memori). Akibatnya, komputasi per langkah waktu pada GRU lebih ringan. Inilah dasar teoretis dari trade-off yang diuji pada penelitian ini: LSTM berpotensi lebih ekspresif karena kapasitasnya lebih besar, sedangkan GRU berpotensi lebih cepat karena strukturnya lebih sederhana.

Sebagaimana pada LSTM, GRU dalam penelitian ini juga diterapkan dalam bentuk dua arah (Bidirectional GRU atau BiGRU). Penjelasan mengenai mekanisme dua arah serta alasan pemilihannya diuraikan pada sub-bab berikut.



Gambar 2.5 Arsitektur Gated Recurrent Unit (GRU) beserta Formulasi Matematisnya

Sumber: Olah (2015)

2.6. Recurrent Neural Network Dua Arah (Bidirectional RNN)

Pada RNN standar (satu arah/unidirectional), informasi mengalir hanya dari masa lalu ke masa depan, sehingga keluaran pada langkah waktu t hanya dipengaruhi oleh masukan sebelum dan pada saat t . Padahal, pada banyak persoalan sekuensial termasuk pengenalan ucapan, konteks sesudah suatu titik waktu juga penting untuk menentukan keluaran yang benar. Sebagai contoh, pengucapan sebuah fonem sering dipengaruhi oleh fonem yang mengikutinya (koartikulasi).

Bidirectional RNN mengatasi keterbatasan ini dengan menggunakan dua lapisan rekuren yang berjalan berlawanan arah pada urutan masukan yang sama:

satu lapisan memproses urutan dari awal ke akhir (arah maju/forward), dan satu lapisan lain memproses dari akhir ke awal (arah mundur/backward). Keluaran pada setiap langkah waktu diperoleh dengan menggabungkan hidden state dari kedua arah tersebut, umumnya melalui operasi penggabungan (concatenation). Dengan demikian, keluaran pada langkah waktu t memuat informasi konteks dari seluruh urutan, baik sebelum maupun sesudah t (Sari & Putra, 2021).

Secara sederhana, jika hidden state arah maju dinyatakan sebagai h_{maju} dan arah mundur sebagai h_{mundur} , maka keluaran gabungan pada langkah waktu t adalah:


$$h_t = [h_{maju,t} ; h_{mundur,t}]$$

Pada penelitian ini, kedua arsitektur yang dibandingkan diterapkan dalam bentuk dua arah, yaitu Bidirectional GRU (BiGRU) dan Bidirectional Long Short-Term Memory (BiLSTM). BiGRU adalah penerapan mekanisme GRU (dua gerbang: update dan reset) dalam dua arah, sedangkan BiLSTM adalah penerapan mekanisme LSTM (tiga gerbang: input, forget, dan output) dalam dua arah. Keduanya menerima urutan vektor fitur dari blok CNN pada arsitektur CRNN, kemudian menghasilkan representasi yang telah memuat konteks dua arah untuk diteruskan ke lapisan keluaran dan fungsi CTC.

Pemilihan bentuk dua arah didasarkan pada karakteristik sinyal ucapan yang bersifat kontekstual dua sisi, sehingga model yang mampu melihat konteks penuh diharapkan menghasilkan transkripsi yang lebih akurat dibandingkan model satu arah (Sari & Putra, 2021). Perbandingan langsung antara BiGRU dan BiLSTM pada arsitektur CRNN untuk Bahasa Indonesia inilah yang menjadi fokus utama penelitian ini, mengingat kajian sebelumnya pada Bahasa Indonesia umumnya masih menggunakan bentuk satu arah (Firmansyah & Bachtiar, 2021).

Tinjauan komprehensif mengenai arsitektur RNN beserta variannya, termasuk LSTM, GRU, dan bentuk dua arah (BiLSTM), menegaskan bahwa pendekatan dua arah secara umum memberikan peningkatan akurasi pada pemodelan data sekuensial (Mienye et al., 2024). Efektivitas BiLSTM pada tugas pengenalan ucapan juga telah dibuktikan pada berbagai penelitian sebelumnya (Wang et al., 2020).

Keterhubungan antara seluruh komponen yang telah dibahas pada Sub-bab 2.3 sampai 2.6, yaitu CNN, RNN, LSTM, GRU, beserta bentuk dua arahnya, dirangkum dalam bentuk peta pada Gambar 2.6.



Gambar 2.6 Peta Keterhubungan CNN, RNN, LSTM, GRU, BiLSTM, dan BiGRU pada Arsitektur CRNN-CTC

Gambar 2.6 memperlihatkan bahwa CNN dan RNN bukan dua pendekatan yang saling bersaing, melainkan dua blok yang menempati posisi berbeda di dalam satu arsitektur CRNN. Pada jalur rekuren, LSTM dan GRU sama-sama merupakan pengembangan dari RNN standar melalui penambahan mekanisme gerbang, dengan perbedaan utama pada jumlah gerbang dan ada tidaknya *cell state* terpisah. Adapun bentuk dua arah, yaitu BiLSTM dan BiGRU, bukan arsitektur baru melainkan cara penerapan: sel yang sama dijalankan dua kali pada arah yang berlawanan lalu keluarannya digabung. Penelitian ini menempatkan BiGRU dan BiLSTM pada posisi Blok RNN yang persis sama, sementara Blok CNN dan Blok CTC dibiarkan identik, sehingga selisih kinerja yang terukur dapat diatribusikan pada perbedaan mekanisme gerbang.

2.7. Connectionist Temporal Classification (CTC) Loss

Dalam pelatihan model ASR, panjang input audio (dalam *frame*) seringkali jauh lebih panjang daripada jumlah karakter label teksnya. Fungsi kerugian *Connectionist Temporal Classification* (CTC) digunakan untuk melatih arsitektur RNN tanpa memerlukan proses penyelarasan waktu (*alignment*) secara manual (Graves et al., 2006). CTC memprediksi distribusi probabilitas pada setiap *frame* dan menggunakan *blank token* untuk menangani duplikasi karakter sebelum merangkainya menjadi kata utuh.

Dalam praktik pengenalan ucapan modern, strategi decoding pada keluaran CTC dapat ditingkatkan melalui beam search yang dipadukan dengan dekoder lain untuk memperbaiki akurasi pada tingkat kata (Sudo et al., 2024).

Secara lebih rinci, CTC bekerja dengan memperkenalkan sebuah token khusus bernama blank yang menandai "tidak ada karakter" pada suatu langkah waktu. Untuk sebuah urutan keluaran, CTC mempertimbangkan seluruh kemungkinan penyelarasan (*alignment*) antara frame audio dan karakter target, lalu menjumlahkan probabilitasnya. Proses mengubah urutan mentah menjadi teks akhir dilakukan dengan dua aturan: pertama, karakter berulang yang berdekatan digabung menjadi satu; kedua, seluruh token blank dihapus. Sebagai contoh, urutan mentah "b-o-o-[blank]-o-k" akan dipetakan menjadi kata "book", karena huruf o ganda yang dipisahkan blank tetap dipertahankan sebagai dua huruf, sedangkan o ganda yang berdekatan tanpa blank digabung.

Fungsi kerugian CTC didefinisikan sebagai negatif logaritma dari total probabilitas seluruh penyelarasan yang valid untuk pasangan masukan X dan target Y :

$$\mathcal{L}_{CTC}(X, Y) = -\ln P(Y | X)$$

$$P(Y | X) = \sum_{\pi \in \mathcal{B}^{-1}(Y)} P(\pi | X)$$

dengan X adalah urutan masukan, Y urutan target, π sebuah jalur penyelarasan (*alignment path*), dan $\mathcal{B}^{-1}(Y)$ himpunan seluruh jalur penyelarasan yang dipetakan menjadi Y oleh fungsi pemetaan banyak-ke-satu $\mathcal{B}$, yakni penggabungan karakter berulang yang berdekatan dan penghapusan seluruh token blank.

Dengan pendekatan ini, model dapat dilatih secara end-to-end langsung dari pasangan audio dan teks tanpa memerlukan penyelarasan manual pada tiap frame, yang dalam praktiknya sulit dan mahal untuk disediakan. Token blank juga memungkinkan model menangani jeda antar kata serta karakter kembar secara alami.

2.8. Decoding Keluaran CTC

Keluaran akhir model CTC bukanlah teks, melainkan matriks probabilitas berukuran jumlah *frame* dikali ukuran kamus token, yang memuat distribusi probabilitas seluruh token pada setiap langkah waktu. *Decoding* adalah proses memilih urutan teks yang paling mungkin dari matriks probabilitas tersebut. Proses ini mencakup penerapan aturan keruntuhan (*collapse*) CTC, yaitu penggabungan token yang berulang secara berurutan dan penghapusan token *blank*, sehingga urutan token per *frame* berubah menjadi teks akhir (Graves et al., 2006). Terdapat dua strategi decoding yang digunakan dalam penelitian ini, yaitu *greedy decoding* dan *beam search decoding*.

2.8.1. Greedy Decoding

Greedy decoding merupakan strategi paling sederhana: pada setiap *frame* dipilih satu token dengan probabilitas tertinggi (*argmax*), kemudian aturan keruntuhan CTC diterapkan pada urutan hasilnya. Pendekatan ini sangat cepat karena hanya memerlukan satu lintasan sepanjang keluaran model. Kelemahannya, keputusan diambil secara lokal per *frame* dan bersifat final; apabila token yang benar hanya terpaut tipis probabilitasnya, kesalahan tersebut tidak dapat dikoreksi lagi. Selain itu, *greedy* hanya menilai satu jalur penyelarasan tunggal, padahal probabilitas sebuah teks menurut CTC adalah jumlah probabilitas dari banyak jalur penyelarasan yang runtuh menjadi teks yang sama.

2.8.2. Beam Search Decoding

Beam search decoding memperbaiki keterbatasan tersebut dengan memelihara sejumlah B kandidat transkripsi terbaik (disebut *beam*) pada setiap langkah waktu, alih-alih hanya satu jalur tunggal. Pada tiap *frame*, seluruh kandidat diperluas dengan setiap token yang mungkin, probabilitasnya diakumulasikan — termasuk menjumlahkan probabilitas beberapa jalur penyelarasan berbeda yang

runtuh menjadi teks yang sama — lalu hanya B kandidat dengan probabilitas tertinggi yang dipertahankan ke langkah berikutnya (Hannun et al., 2014). Transkripsi akhir adalah kandidat dengan probabilitas total tertinggi. Lebar beam B menjadi parameter kompromi antara akurasi dan waktu komputasi: beam yang lebih besar menelusuri lebih banyak kemungkinan sehingga berpeluang lebih akurat, tetapi peningkatan akurasinya semakin mengecil sementara waktu decoding terus bertambah (Sudo et al., 2024). Dalam penelitian ini *greedy decoding* digunakan pada eksperimen Tahap 1 sebagai konfigurasi dasar, sedangkan *beam search decoding* dengan lebar beam 10 tanpa *language model* eksternal diterapkan pada eksperimen Tahap 2 dan Tahap 3.

2.9. Metrik Evaluasi Kinerja (WER dan CER)

Untuk mengevaluasi performa model *Speech-to-Text* secara kuantitatif, metrik standar yang digunakan adalah *Word Error Rate* (WER) dan *Character Error Rate* (CER) (Wijaya & Santoso, 2023). Keduanya dihitung menggunakan algoritma jarak Levenshtein (*Levenshtein distance*).

- **Word Error Rate (WER):** Mengukur tingkat kesalahan pada level kata. Rumus matematis untuk WER adalah:

$$WER = \frac{S + D + I}{N \text{ kata}}$$

- **Character Error Rate (CER):** Mengukur tingkat kesalahan pada level karakter/huruf. Rumus matematis untuk CER adalah:

$$CER = \frac{S + D + I}{N \text{ karakter}}$$

Di mana variabel penyusun rumusnya adalah:

- *S* : *Substitution* (Jumlah kata/huruf yang terganti secara salah)
- *D* : *Deletion* (Jumlah kata/huruf yang terhapus/hilang)
- *I* : *Insertion* (Jumlah kata/huruf tambahan yang tidak seharusnya ada)
- *N* : Total kata atau karakter pada teks referensi (*ground truth*)

Semakin rendah nilai persentase WER dan CER, maka semakin akurat performa model dalam melakukan transkripsi teks.

Kedua metrik tersebut merupakan metrik kesalahan, sehingga tingkat akurasi model dapat diturunkan langsung darinya: akurasi pada tingkat kata dinyatakan sebagai $100\% - \text{WER}$, dan akurasi pada tingkat karakter sebagai $100\% - \text{CER}$. Sebagai contoh, model dengan WER 26% berarti mampu mengenali sekitar 74% kata dengan benar. Dalam laporan ini hasil eksperimen disajikan dalam bentuk WER dan CER sesuai konvensi penelitian ASR, dan nilai akurasi padanannya dicantumkan pada pembahasan hasil akhir.

2.10. Overfitting dan Teknik Penanganannya

Overfitting adalah kondisi ketika model terlalu menyesuaikan diri terhadap data latih hingga menghafal pola-pola spesifiknya, sehingga performanya baik pada data latih tetapi buruk pada data baru. Gejala umumnya terlihat dari *loss* data latih yang terus menurun sementara *loss* data validasi berhenti membaik atau justru naik. Jaringan rekuren berukuran besar yang dilatih pada data terbatas — seperti pada kasus bahasa dengan sumber daya rendah (*low-resource language*) — sangat rentan terhadap kondisi ini (Shiri et al., 2024). Terdapat tiga kelompok teknik penanganan yang relevan dengan penelitian ini, yaitu regularisasi, augmentasi data, dan penambahan data latih.

2.10.1. Regularisasi

Regularisasi membatasi kapasitas model agar tidak menghafal data latih. Teknik yang umum digunakan pada jaringan rekuren adalah *dropout*, yaitu menonaktifkan sebagian neuron secara acak dengan peluang tertentu pada setiap langkah pelatihan, sehingga model tidak dapat bergantung pada sekelompok kecil neuron dan pengetahuannya dipaksa tersebar (Mienye et al., 2024). Teknik pendampingnya adalah *weight decay*, yang memberikan penalti terhadap bobot bernilai besar agar model tetap sederhana. Keduanya hanya aktif saat pelatihan; saat inferensi seluruh neuron digunakan kembali.

2.10.2. Augmentasi Data

Mengingat tantangan dalam pengolahan *low-resource language*, teknik *Data Augmentation* sering digunakan untuk menambah variasi data latih secara sintetis. Penerapan augmentasi pada data audio (seperti penambahan *noise*, variasi

pitch, atau peregangan waktu) terbukti dapat meningkatkan ketahanan (*robustness*) dan akurasi model *Deep Learning* secara signifikan (Ramadhan & Wibowo, 2024).

Selain augmentasi pada gelombang suara seperti penambahan derau dan variasi penguatan (*gain*), augmentasi juga dapat diterapkan langsung pada Mel-Spectrogram melalui penutupan acak sebagian rentang waktu (*time masking*) dan pita frekuensi (*frequency masking*), yang memaksa model belajar dari konteks di sekitarnya alih-alih bergantung pada satu potongan informasi.

2.10.3. Penambahan Data Latih

Penanganan yang paling mendasar adalah memperbesar jumlah data latih itu sendiri. Semakin banyak dan beragam contoh yang dilihat model, semakin kecil peluangnya menghafal sampel individual, dan performa sistem pengenalan ucapan *end-to-end* secara konsisten meningkat seiring bertambahnya skala data latih (Prabhavalkar et al., 2024). Dalam penelitian ini regularisasi dan augmentasi data diterapkan mulai eksperimen Tahap 2, sedangkan penambahan data latih dilakukan pada Tahap 3 melalui perluasan dataset.

Alasan mengapa penambahan jumlah data dapat meningkatkan akurasi dapat dijelaskan sebagai berikut. Model dengan jutaan parameter memiliki dua cara untuk menekan nilai kerugian pada data latih, yaitu menghafal contoh yang dilihatnya atau menemukan pola umum yang berlaku pada seluruh contoh. Ketika data latih sedikit, menghafal justru merupakan jalan yang lebih mudah, sehingga model bekerja baik pada data latih namun gagal pada data uji. Semakin banyak data yang tersedia, semakin mahal biaya menghafal dan semakin menguntungkan menemukan pola umum. Khusus pada pengenalan ucapan, penambahan data juga membawa lebih banyak penutur, aksen, kecepatan bicara, dan kondisi perekaman yang berbeda, sehingga model memperoleh contoh bunyi yang lebih beragam untuk setiap fonem yang harus dikenalnya.

2.11. Studi Literatur Terkait

Sub-bab ini merangkum sejumlah penelitian terdahulu yang berkaitan langsung dengan penelitian ini, baik dari sisi bahasa yang dikaji, arsitektur yang digunakan, maupun cara perbandingan yang diterapkan. Rangkuman tersebut

disajikan pada Tabel 2.1, kemudian diuraikan setelahnya untuk menunjukkan posisi penelitian ini di antara penelitian yang sudah ada.

Tabel 2.1 *Ringkasan Penelitian Terdahulu yang Relevan*

Peneliti (Tahun)	Data dan Bahasa	Fitur dan Arsitektur	Hasil Utama
Graves et al. (2006)	TIMIT (Inggris)	RNN dua arah + CTC	Memperkenalkan CTC sehingga RNN dapat dilatih tanpa penyalarsan manual per frame
Hannun et al. (2014)	Korpus Inggris skala ribuan jam	Spektrogram + RNN 5 lapis + CTC (Deep Speech)	Menunjukkan pendekatan end-to-end mampu menyaingi sistem berbasis HMM
Shewalkar et al. (2019)	TED-LIUM (Inggris)	Perbandingan RNN, LSTM, dan GRU	LSTM memperoleh WER terbaik, sedangkan GRU lebih cepat dengan WER yang berdekatan
Firmansyah & Bachtiar (2021)	Bahasa Indonesia	GRU satu arah (unidirectional)	Menerapkan GRU untuk ASR Bahasa Indonesia tanpa komparasi antar-varian rekuren
Arisaputra & Zahra (2022)	TITML-IDN, Magic Data, Common Voice (+/- 24 jam)	Penalaan model pralatih XLSR-53	WER 20%, turun menjadi 12% setelah ditambah language model eksternal
Telmem et al. (2024)	Bahasa Amazigh (sumber daya terbatas)	Spektrogram + CNN, LSTM, dan CNN-LSTM	Model hibrida CNN-LSTM mengungguli CNN maupun LSTM secara terpisah
Dwijayanti et al. (2024)	Rekaman 10 responden (Indonesia)	MFCC + Deep BiLSTM	WER rata-rata 24,99% pada kondisi ruangan sunyi
Endah et al. (2025)	1.410 ucapan, 23 penutur (Indonesia)	MFCC + Conv-BiLSTM + CTC	Penambahan lapisan konvolusi menurunkan WER rata-rata 15,56%; WER terbaik 27,14%
Penelitian ini (2026)	Mozilla Common Voice cv-id, 30.256 ucapan	Mel-Spectrogram + CRNN (BiGRU vs BiLSTM) + CTC	Komparasi head-to-head pada konfigurasi identik: BiLSTM 26,36%, BiGRU 28,13%

Dari sisi metode penyalarsan, Graves et al. (2006) meletakkan dasar bagi hampir seluruh penelitian pada Tabel 2.1 melalui pengenalan fungsi kerugian CTC, yang memungkinkan model dilatih langsung dari pasangan audio dan teks tanpa penandaan waktu per frame. Hannun et al. (2014) kemudian membuktikan bahwa pendekatan *end-to-end* berbasis CTC dapat menyaingi sistem konvensional

berbasis HMM, dan menjadi rujukan utama bagi arsitektur *Deep Speech* yang mendasari penelitian ini.

Kajian yang secara khusus membandingkan varian lapisan rekuren dilakukan oleh Shewalkar et al. (2019) pada korpus TED-LIUM berbahasa Inggris. Temuan mereka menunjukkan LSTM memperoleh WER terbaik sementara GRU mencapai waktu optimasi yang lebih singkat dengan WER yang berdekatan. Pola tersebut sejalan dengan hasil penelitian ini, sehingga memperkuat dugaan bahwa keunggulan LSTM berasal dari perbedaan struktur sel dan bukan dari kekhususan suatu bahasa tertentu.

Pada konteks Bahasa Indonesia, Firmansyah dan Bachtiar (2021) menerapkan GRU satu arah, sedangkan Dwijayanti et al. (2024) dan Endah et al. (2025) menggunakan BiLSTM. Penelitian Endah et al. (2025) merupakan pembandingan yang paling dekat konteksnya karena sama-sama memakai arsitektur gabungan konvolusi dan BiLSTM dengan CTC untuk ucapan kontinu Bahasa Indonesia. Penelitian tersebut melaporkan bahwa penambahan lapisan konvolusi menurunkan WER rata-rata sebesar 15,56% dan mencapai WER terbaik 27,14%, berada pada rentang yang sama dengan hasil penelitian ini. Adapun Arisaputra dan Zahra (2022) menempuh jalur berbeda, yaitu menala model pralatih XLSR-53, dan memperoleh WER yang lebih rendah dengan kebutuhan data berlabel yang jauh lebih sedikit.

Berdasarkan Tabel 2.1 dapat diidentifikasi tiga celah penelitian (*research gap*) yang menjadi dasar penelitian ini. Pertama, penelitian yang membandingkan varian lapisan rekuren secara langsung umumnya dilakukan pada bahasa Inggris dengan korpus yang jauh lebih besar, sehingga temuannya belum tentu berlaku pada kondisi sumber daya terbatas. Kedua, penelitian ASR Bahasa Indonesia yang menggunakan arsitektur rekuren pada umumnya hanya menerapkan satu varian saja, tanpa membandingkannya dengan varian lain pada konfigurasi yang identik. Ketiga, penelitian Bahasa Indonesia yang menggunakan arsitektur gabungan konvolusi dan rekuren sejauh ini masih memakai MFCC sebagai fitur masukan serta korpus rekaman mandiri berskala kecil, sedangkan penelitian ini menggunakan Mel-Spectrogram pada korpus publik berskala lebih besar sehingga hasilnya lebih mudah direproduksi peneliti lain.

Perlu ditegaskan bahwa nilai WER pada Tabel 2.1 tidak dapat diperbandingkan secara langsung satu sama lain, karena setiap penelitian menggunakan korpus, jumlah penutur, tingkat derau, dan ukuran kosakata yang berbeda. Nilai tersebut dicantumkan sebagai gambaran rentang kinerja yang lazim dilaporkan, bukan sebagai peringkat.

Terkait keadaan mutakhir bidang ini, perkembangan sistem ASR telah bergeser dari arsitektur rekuren menuju arsitektur berbasis *Transformer* dan *Conformer*, serta model pralatih swa-selia (*self-supervised*) berskala besar seperti wav2vec 2.0 dan Whisper yang dilatih pada ratusan ribu jam data multibahasa (Prabhavalkar et al., 2024). Untuk Bahasa Indonesia, pendekatan penalaan model pralatih tersebut terbukti mencapai WER yang lebih rendah dengan data berlabel yang jauh lebih sedikit (Arisaputra & Zahra, 2022; Pratama & Amrullah, 2024). Arsitektur CRNN-CTC yang dikaji pada penelitian ini karena itu tidak diposisikan sebagai sistem terancang, melainkan sebagai arsitektur yang dilatih sepenuhnya dari awal (*from scratch*) sehingga pengaruh satu komponen, dalam hal ini jenis lapisan rekuren, dapat diisolasi dan diukur secara bersih. Kondisi tersebut justru sulit dicapai pada model pralatih, karena sebagian besar kemampuannya berasal dari tahap pralatihan dan bukan dari pilihan lapisan tertentu.

Adapun pemanfaatan terdekat dari hasil penelitian ini bersifat sebagai rujukan praktik (*best practice*) dalam perancangan sistem, bukan sebagai produk siap pakai. Rekomendasi yang dapat diambil ada tiga: mendahulukan penambahan data latih dibandingkan penggantian varian lapisan rekuren, memilih BiLSTM apabila akurasi menjadi prioritas, serta memilih BiGRU apabila kecepatan inferensi dan ukuran model lebih diutamakan, misalnya pada penerapan di perangkat dengan sumber daya terbatas. Model CRNN-CTC berukuran di bawah 40 MB seperti pada penelitian ini juga masih memungkinkan dijalankan secara luring (*offline*) pada perangkat biasa, yang menjadi kelebihan dibandingkan model pralatih berskala besar.

BAB III

METODOLOGI PENELITIAN

3.1. Analisis Sistem Pengenalan Suara Saat Ini

Saat ini, teknologi pengenalan suara (*Automatic Speech Recognition* / ASR) banyak didominasi oleh layanan berbasis *cloud* dari perusahaan besar. Meskipun memiliki akurasi tinggi, sistem tersebut bersifat tertutup (*black-box*), sangat bergantung pada konektivitas internet, dan arsitekturnya sulit dimodifikasi untuk kebutuhan penelitian spesifik. Oleh karena itu, diperlukan perancangan sistem ASR secara mandiri (*offline*) menggunakan arsitektur *Deep Learning* agar peneliti dapat mengontrol penuh proses ekstraksi fitur, mengubah parameter pelatihan, dan membandingkan kinerja antar model secara transparan.

3.2. Analisis Dataset dan Pustaka yang Digunakan

Dalam membangun sistem ini, pengembangan tidak menggunakan API (Application Programming Interface) pihak ketiga, melainkan memanfaatkan dataset dan pustaka (library) open-source berbasis bahasa pemrograman Python, di antaranya:

- PyTorch: Merupakan *framework Deep Learning* utama yang digunakan untuk membangun arsitektur jaringan saraf tiruan (CRNN), mendefinisikan layer (CNN, GRU, LSTM), serta melakukan komputasi tensor menggunakan akselerasi GPU.
- Torchaudio dan Soundfile: Pustaka yang digunakan khusus untuk pemrosesan sinyal audio, seperti memuat file .wav dan melakukan transformasi ekstraksi fitur menjadi *Mel-Spectrogram*.
- Dataset: Menggunakan korpus *Mozilla Common Voice* spesifik bahasa Indonesia (cv-id).

3.2.1. Deskripsi dan Spesifikasi Dataset

Dataset yang digunakan dalam penelitian ini bersumber dari korpus publik Mozilla Common Voice untuk Bahasa Indonesia (cv-id). Penelitian ini melibatkan dua rilis korpus: Common Voice Corpus 25.0 (rilis 9 Maret 2026) pada eksperimen Tahap 1 dan Tahap 2, serta Common Voice Corpus

24.0 (rilis 5 Desember 2025) pada eksperimen Tahap 3. Penggunaan dua rilis ini tidak memengaruhi validitas perbandingan, karena korpus Common Voice bersifat kumulatif sehingga kedua rilis berasal dari korpus yang sama dengan selisih data tervalidasi hanya 75 berkas atau sekitar 0,25%. Selain itu, pada setiap tahap eksperimen kedua arsitektur dilatih menggunakan dataset yang identik, sehingga perbedaan rilis korpus tidak menjadi variabel pembeda antara BiGRU dan BiLSTM.

Mozilla Common Voice merupakan korpus suara terbuka yang dibangun secara gotong royong (*crowdsourced*). Sukarelawan membacakan kalimat yang ditampilkan pada layar, kemudian sukarelawan lain menyimak rekaman tersebut dan menilai apakah bunyinya sesuai dengan kalimat yang tertulis. Sebuah rekaman baru berstatus tervalidasi apabila memperoleh sekurang-kurangnya dua penilaian setuju (Ardila et al., 2020). Kalimat yang dibacakan bukan percakapan spontan, melainkan diambil dari kumpulan kalimat berlisensi terbuka yang disumbangkan komunitas, sehingga isinya berupa kalimat pendek umum dan bukan wacana bertema khusus. Karena itu korpus ini tidak memiliki kategori topik. Metadata yang tersedia berupa keterangan opsional mengenai penutur seperti umur, jenis kelamin, dan aksen, yang pengisiannya bergantung pada kesediaan masing-masing kontributor sehingga tidak selalu lengkap.

Dari sisi volume, korpus Common Voice secara keseluruhan mencakup puluhan bahasa dengan total ribuan jam rekaman (Ardila et al., 2020). Porsi Bahasa Indonesia jauh lebih kecil dibandingkan bahasa dengan sumber daya melimpah: pada rilis yang digunakan penelitian ini, jumlah rekaman tervalidasi Bahasa Indonesia sebanyak 30.256 berkas. Sebagai pembandingan, sistem ASR *end-to-end* berbahasa Inggris seperti *Deep Speech* dilatih menggunakan data berskala ribuan jam (Hannun et al., 2014). Perbandingan tersebut menegaskan status Bahasa Indonesia sebagai bahasa dengan sumber daya terbatas (*low-resource language*), sekaligus menjelaskan mengapa perluasan dataset pada Tahap 3 memberikan pengaruh yang begitu besar terhadap kinerja model.

Untuk memenuhi kebutuhan pelatihan dan pengujian model, dataset ini memiliki spesifikasi teknis dan pembagian sebagai berikut:

1. Jenis Data

Data masukan (*input*) berupa rekaman suara (*speech*) yang diucapkan oleh berbagai kontributor (*crowdsourced*). File audio ini disimpan dalam format digital berekstensi .wav (hasil konversi dari format .mp3 bawaan Mozilla) bersaluran tunggal (*mono*) dengan frekuensi *sampling* 16.000 Hz. Pemilihan format dan frekuensi ini disesuaikan dengan standar masukan untuk proses ekstraksi fitur *Mel-Spectrogram*.

2. Jumlah Dataset

Pada eksperimen tahap awal (Tahap 1 dan Tahap 2), dataset yang digunakan berjumlah 12.138 data. Jumlah tersebut diperoleh dengan menggabungkan seluruh berkas pembagian bawaan korpus, yaitu *train.tsv*, *dev.tsv*, dan *test.tsv*, kemudian membaginya ulang menggunakan skrip *split_dataset.py* dengan rasio 80:10:10. Pengacakan dilakukan menggunakan nilai seed tetap sebesar 42 agar pembagian bersifat reproduktibel. Jumlah ini kemudian diperluas pada Tahap 3 sebagaimana dijelaskan pada Sub-bab 3.2.2. Hasil pembagiannya adalah sebagai berikut:

- **Data Latih (*Train Set*):** Sebanyak **9.710 data** (bersumber dari *train.tsv*), digunakan secara masif untuk melatih bobot jaringan model CRNN.
- **Data Validasi:** Sebanyak **1.213 data** (bersumber dari *dev.tsv*), digunakan untuk memvalidasi performa model pada setiap akhir epoch saat proses pelatihan berlangsung.
- **Data Uji (*Test Set*):** Sebanyak **1.215 data** (bersumber dari *test.tsv*), digunakan untuk pengujian inferensi akhir menggunakan metrik *Word Error Rate* (WER) dan *Character Error Rate* (CER).

3. Pelabelan *Ground Truth*

Pelabelan teks acuan atau *ground truth* untuk setiap rekaman audio dikelola menggunakan file berekstensi .tsv. Format penyimpanan di dalam file tersebut menggunakan metode *Tab-Separated Values*, di mana kolom path yang berisi identitas file audio dipetakan secara langsung dengan kolom sentence yang memuat teks ucapan aslinya. Sebelum menjadi target pembelajaran model melalui fungsi *CTC Loss*, teks *ground truth* ini melewati tahap pra-pemrosesan teks (*text normalization*) yang meliputi

pengubahan huruf menjadi huruf kecil (*lowercasing*) serta penghapusan tanda baca, sehingga model berfokus murni pada penyelarasan karakter alfabet dasar (a-z) dan spasi.

Perlu ditegaskan bahwa satuan pengenalan pada penelitian ini adalah karakter, bukan kata. Model tidak memiliki daftar kosakata Bahasa Indonesia. Keluarannya berupa urutan karakter yang dipilih dari kamus 30 token, yang terdiri atas 26 huruf a sampai z, spasi, apostrof, serta token *blank* dan *unknown*, sebagaimana dirinci pada Tabel 4.3. Kata terbentuk dengan sendirinya dari posisi karakter spasi yang diprediksi model. Konsekuensinya, model dapat menghasilkan rangkaian huruf yang sebenarnya bukan kata Bahasa Indonesia yang sah, sebagaimana terlihat pada contoh kesalahan di Sub-bab 4.8, karena tidak ada mekanisme yang memaksa keluarannya berupa kata yang terdaftar dalam suatu kamus.

Adapun acuan masukan pada tingkat kalimat adalah satu berkas audio yang berpasangan dengan satu kalimat penuh pada kolom *sentence* di berkas .tsv. Satu contoh data (*sample*) karena itu berupa satu ucapan utuh, bukan potongan kata atau suku kata. Panjang kalimat bervariasi mengikuti korpus dan tidak dibatasi jumlah katanya; contoh kalimat yang muncul pada data uji dapat dilihat pada Tabel 4.11 dan Tabel 4.12, dengan panjang berkisar antara lima hingga sembilan kata.

3.2.2. Perluasan Dataset untuk Eksperimen Lanjutan

Hasil eksperimen awal (dibahas pada Bab IV) menunjukkan nilai WER dan CER yang masih tergolong tinggi ketika model dilatih menggunakan pembagian awal train.tsv/dev.tsv/test.tsv (total 12.138 data). Untuk mengatasi keterbatasan ini, dilakukan perluasan dataset dengan memanfaatkan berkas *validated.tsv* pada korpus Mozilla Common Voice Bahasa Indonesia, yaitu kumpulan seluruh data yang telah tervalidasi oleh komunitas namun belum dipartisi menjadi subset train/dev/test bawaan. Berkas ini memuat 30.256 data tervalidasi, jauh lebih banyak dibandingkan pembagian bawaan yang hanya menggunakan sebagian kecil darinya.

Perlu ditegaskan bahwa perluasan dari 12.138 menjadi 30.256 data ini berasal sepenuhnya dari rekaman asli penutur pada berkas *validated.tsv*, dan sama

sekali bukan hasil augmentasi. Kedua hal tersebut berbeda dan bekerja pada tataran yang berlainan. Perluasan dataset menambah jumlah ucapan yang berbeda beserta penutur, kalimat, dan kondisi rekaman yang baru, sehingga jumlah data latih benar-benar bertambah. Augmentasi tidak menambah jumlah berkas sama sekali, melainkan mengubah sedikit rekaman yang sudah ada setiap kali dibaca pada saat pelatihan. Dengan kata lain, angka 30.256 pada Tahap 3 adalah jumlah rekaman yang nyata ada di dalam korpus, bukan hasil penggandaan buatan.

Pembagian ulang dataset dilakukan menggunakan skrip `split_validated.py` dengan rasio 90% data latih, 5% data validasi, dan 5% data uji, menghasilkan 27.230 data latih, 1.512 data validasi, dan 1.514 data uji (Tabel 3.1). Perlu dicatat bahwa pembagian ini dilakukan secara acak per baris (per-clip), bukan per kontributor (per-speaker), sehingga terdapat kemungkinan suara dari kontributor yang sama muncul pada subset train dan test sekaligus. Keterbatasan metodologis ini disadari sepenuhnya dan didiskusikan lebih lanjut pada Sub-bab 4.13.

Tabel 3.1 Perbandingan Ukuran Dataset Sebelum dan Sesudah Perluasan

Subset	Dataset Awal (train/dev/test.tsv)	Dataset Perluasan (validated.tsv, rasio 90:5:5)
Data Latih (Train)	9.710	27.230
Data Validasi	1.213	1.512
Data Uji (Test)	1.215	1.514
Total	12.138	30.256

3.3. Analisis Jangkauan Suara dan Batasan Sistem

Sistem kecerdasan buatan yang dibangun ini memiliki jangkauan dan ruang lingkup pengujian sebagai berikut:

1. Sistem hanya dilatih dan diuji untuk mengenali kosa kata serta struktur fonetik dalam Bahasa Indonesia.
2. Format masukan suara yang dijangkau oleh sistem adalah berkas audio

digital berformat .wav.

3. Target teks keluaran sistem difokuskan pada huruf alfabet dasar (a-z) dan spasi, tanpa melibatkan pengenalan tanda baca khusus maupun kapitalisasi huruf.

3.4. Analisis Sistem yang Akan Dibangun


Sistem yang dibangun adalah model pembelajaran mesin berbasis *Convolutional Recurrent Neural Network* (CRNN) yang dipadukan dengan pemetaan *Connectionist Temporal Classification* (CTC) untuk menerjemahkan ucapan suara menjadi teks.

3.4.1. Deskripsi Kebutuhan Sistem

Sistem membutuhkan kemampuan untuk mengeksekusi tiga tahapan utama:

- **Pra-pemrosesan Data:** Mengubah sinyal audio satu dimensi menjadi gambar representasi visual dua dimensi (*Mel-Spectrogram*) agar pola frekuensi dapat dibaca oleh komputer.
- **Pelatihan Model (*Training*):** Mempelajari pola pemetaan antara suara dan teks target hingga maksimum 50 putaran iterasi (*epoch*). Pelatihan dihentikan lebih awal (*early stopping*) apabila validation WER tidak membaik selama 5 epoch berturut-turut.
- **Inferensi / Pengujian:** Menerima masukan rekaman audio baru dan memprediksi teks transkripsinya dalam waktu yang singkat.

Hasil tahap pra-pemrosesan tersebut ditunjukkan pada Gambar 3.1, yang menampilkan representasi Mel-Spectrogram dari salah satu rekaman masukan. Sumbu horizontal menyatakan waktu dalam detik, sumbu vertikal menyatakan frekuensi dalam skala Mel, dan intensitas warna menyatakan besarnya energi dalam desibel. Representasi dua dimensi inilah yang selanjutnya diperlakukan sebagai citra masukan bagi blok CNN pada arsitektur sistem.



Gambar 3.1 Representasi Fitur Mel-Spectrogram dari Suara Masukan

3.4.2. Deskripsi Kebutuhan Perangkat Keras

Proses pelatihan model *Deep Learning* membutuhkan komputasi matriks yang sangat masif, sehingga memerlukan akselerasi perangkat keras yang memadai. Spesifikasi perangkat keras yang digunakan dirangkum pada Tabel 3.2.

Tabel 3.2 Spesifikasi Perangkat Keras

Komponen	Spesifikasi
Prosesor (CPU)	Intel® Core™ i5-12400F (12th Gen) @ 2.50 GHz (12 CPUs)
Memori (RAM)	16 GB DDR4
Kartu Grafis (GPU)	NVIDIA GeForce RTX 3060

3.4.3. Deskripsi Kebutuhan Perangkat Lunak

Agar perangkat keras dapat menjalankan proses pelatihan kecerdasan buatan secara optimal, diperlukan konfigurasi perangkat lunak seperti yang ditunjukkan pada Tabel 3.3.

Tabel 3.3 Spesifikasi Perangkat Lunak

Komponen	Spesifikasi
Sistem Operasi	Windows 10 Pro 64-bit
Bahasa Pemrograman	Python versi 3.11.9
Framework Deep Learning	PyTorch versi 2.11.0
Pustaka Pemrosesan Audio	Torchaudio versi 2.11.0
Arsitektur Komputasi GPU	CUDA Toolkit versi 12.1

3.4.4. Spesifikasi Parameter Pelatihan Model

Untuk memastikan model belajar dengan optimal, sistem menggunakan pengaturan *hyperparameter* sebagai berikut:

- **Epoch:** 50, dengan mekanisme early stopping berdasarkan validation WER (patience 5 epoch) (Batas maksimum perulangan model mempelajari seluruh dataset latih).
- **Fungsi Optimasi:** AdamW (Untuk memperbarui bobot jaringan secara efisien).
- **Fungsi Loss:** CTC Loss (Untuk menyelaraskan prediksi karakter dengan teks target).
- **Ukuran Batch (Batch Size):** 16 data per iterasi pelatihan.
- **Ekstraksi Fitur (Mel-Spectrogram):** 80 filter mel ($n_mels = 80$) pada rentang frekuensi 0–8.000 Hz, dengan n_fft 400, panjang jendela 400 sampel (25 ms), dan hop length 160 sampel (10 ms). Nilai 80 dipilih karena merupakan standar yang lazim pada arsitektur ASR end-to-end modern: cukup rinci untuk membedakan pola bunyi ucapan tanpa membebani komputasi secara berlebihan. Nilai ini sekaligus menentukan dimensi masukan jaringan, yaitu Mel-Spectrogram berukuran $80 \times T$ (T = jumlah frame), yang setelah dua kali

pooling frekuensi pada blok CNN ($80 \rightarrow 40 \rightarrow 20$) menghasilkan vektor fitur berdimensi 2.560 ($128 \text{ kanal} \times 20 \text{ bin}$) per langkah waktu sebagai masukan lapisan rekuren.

- **Lapisan Ekstraksi Fitur Spasial (CNN):** 3 blok konvolusi berurutan dengan $32 \rightarrow 64 \rightarrow 128$ kanal, masing-masing tersusun atas Conv2D (kernel 3×3 , stride 1, padding 1) + BatchNorm2D + ReLU. MaxPooling2D (kernel 2×1) disisipkan setelah blok pertama dan kedua untuk mereduksi dimensi frekuensi tanpa mengubah resolusi waktu, sehingga panjang frame tetap terjaga untuk penyelarasan CTC. Blok ditutup dengan dropout 0,1. Masukan berupa Mel-Spectrogram 80 filter mel, menghasilkan vektor fitur berdimensi 2.560 ($128 \text{ kanal} \times 20 \text{ bin frekuensi}$) per langkah waktu.
- **Lapisan Rekuren:** 3 lapisan tersusun (*stacked*) dengan 256 unit tersembunyi (*hidden size*) per arah, serta *dropout* 0,1 di antar lapisan.
- **Laju Pembelajaran (Learning Rate):** 3×10^{-4} , dengan penjadwalan *ReduceLROnPlateau* (faktor 0,5, patience 2 epoch berdasarkan validation loss).
- **Regularisasi:** *weight decay* 1×10^{-2} pada optimizer AdamW, serta pemotongan gradien (*gradient clipping*) dengan norma maksimum 5,0 untuk menjaga stabilitas pelatihan.

3.4.5. Dasar Pemilihan Parameter Model

Seluruh nilai parameter pada Sub-bab 3.4.4 ditetapkan sebelum eksperimen dijalankan dan tidak diubah selama perbandingan berlangsung. Penetapan tersebut tidak dilakukan melalui pencarian parameter secara menyeluruh (*hyperparameter search*), melainkan mengacu pada tiga pertimbangan: nilai yang lazim digunakan pada arsitektur ASR *end-to-end* sejenis, batas kemampuan perangkat keras yang tersedia, serta syarat keadilan perbandingan.

Pertimbangan terakhir merupakan yang terpenting. Karena tujuan penelitian ini adalah membandingkan BiGRU dengan BiLSTM, seluruh parameter di luar jenis lapisan rekuren harus dibuat identik pada kedua skenario. Apabila masing-masing model disetel secara terpisah dengan parameter terbaiknya sendiri, selisih kinerja yang terukur tidak lagi dapat diatribusikan pada perbedaan mekanisme

gerbang, melainkan bercampur dengan perbedaan hasil penyetelan. Dasar pemilihan tiap parameter dirangkum pada Tabel 3.4.

Tabel 3.4 *Dasar Pemilihan Nilai Parameter Pelatihan Model*

Parameter	Nilai	Dasar Pemilihan
Jumlah filter mel (n_mels)	80	Rentang lazim 64 sampai 80 pada arsitektur ASR end-to-end (Hannun et al., 2014). Nilai 80 memberi resolusi frekuensi memadai tanpa melampaui batas resolusi jendela FFT 400 sampel.
Blok CNN	3 blok, 32-64-128 kanal	Pola penggandaan jumlah kanal yang lazim pada jaringan konvolusi. Jumlah kanal sengaja dijaga tetap kecil agar sebagian besar kapasitas model berada pada lapisan rekuren yang menjadi objek perbandingan.
Ukuran tersembunyi (hidden size)	256 per arah	Nilai 64 dan 128 memberi kapasitas yang terlalu kecil untuk memodelkan ucapan kontinu dengan kamus 30 karakter. Nilai 512 melipatgandakan jumlah parameter lapisan rekuren sehingga waktu pelatihan dan kebutuhan memori GPU meningkat tajam tanpa jaminan perbaikan yang sepadan pada ukuran data yang tersedia.
Jumlah lapisan rekuren	3 lapisan bertumpuk	Lapisan bertumpuk memungkinkan terbentuknya representasi bertingkat. Penambahan lapisan pada dataset terbatas justru memperbesar risiko overfitting; penelitian sejenis mencatat WER kembali memburuk setelah melewati jumlah lapisan tertentu (Endah et al., 2025).
Dropout	0,1 (Tahap 1); 0,3 (Tahap 2 dan 3)	Nilai 0,1 dipilih sebagai regularisasi ringan pada baseline. Nilai 0,3 digunakan setelah gejala overfitting teramati pada Tahap 1, dan sejalan dengan temuan Endah et al. (2025) bahwa dropout 0,3 memberikan WER terendah pada Bi-LSTM bertumpuk.
Laju pembelajaran	3×10^{-4}	Nilai baku yang lazim untuk optimizer keluarga Adam pada pelatihan berbasis CTC. Disertai penjadwalan ReduceLROnPlateau sehingga laju menurun otomatis ketika loss validasi berhenti membaik, tanpa perlu disetel manual.
Optimizer	AdamW, weight decay 1×10^{-2}	AdamW memisahkan penalti bobot dari pembaruan gradien sehingga regularisasi bekerja lebih konsisten dibandingkan Adam biasa (Loshchilov & Hutter, 2019).
Ukuran batch	16	Ditetapkan berdasarkan kapasitas memori GPU yang tersedia. Ukuran ini masih dapat dijalankan pada model dengan parameter terbanyak (BiLSTM), sehingga nilai yang sama dapat dipakai pada kedua skenario demi keadilan perbandingan.
Jumlah epoch	Maksimum 50, early stopping patience 5	Batas 50 ditetapkan berdasarkan perkiraan waktu pelatihan yang wajar pada perangkat yang tersedia. Nilai ini bukan penentu tunggal karena early stopping menghentikan pelatihan secara otomatis ketika WER validasi tidak lagi membaik.
Gradient clipping	Norma maksimum 5,0	Mencegah lonjakan gradien yang lazim terjadi pada pelatihan berbasis CTC ketika model belum stabil pada epoch-epoch awal.

Perlu ditegaskan bahwa blok CNN pada penelitian ini bukan arsitektur pralatih (*pre-trained*) seperti VGG, ResNet, atau AlexNet, melainkan disusun sendiri dan dilatih sepenuhnya dari awal (*from scratch*) bersama lapisan rekuren dalam satu proses pelatihan *end-to-end*. Pilihan ini diambil karena arsitektur pralatih tersebut dirancang untuk citra alami berkanal tiga (RGB) dengan ukuran masukan tetap, sedangkan masukan pada penelitian ini berupa Mel-Spectrogram berkanal tunggal dengan panjang waktu yang berbeda-beda antar rekaman. Selain itu, penggunaan blok CNN sederhana yang tidak pralatih memastikan seluruh kemampuan model berasal dari data latih penelitian ini sendiri, sehingga perbandingan antara BiGRU dan BiLSTM tidak terpengaruh pengetahuan yang dibawa dari sumber lain.

Khusus mengenai *epoch*, satu *epoch* berarti satu kali putaran ketika model telah melihat seluruh data latih tepat satu kali. Karena data diproses dalam kelompok kecil (*batch*) berisi 16 ucapan, satu *epoch* pada Tahap 3 dengan 27.230 data latih terdiri atas sekitar 1.702 iterasi pembaruan bobot. Model tidak cukup melihat data satu kali saja, sebab bobot diperbarui sedikit demi sedikit pada setiap iterasi sehingga diperlukan pengulangan berkali-kali hingga pemetaan dari pola bunyi ke urutan karakter terbentuk. Sebaliknya, pengulangan yang terlalu banyak membuat model mulai menghafal data latih. Karena itu jumlah *epoch* tidak ditetapkan secara kaku, melainkan dibatasi maksimum 50 dan dihentikan lebih awal oleh mekanisme *early stopping*.

3.4.6. Skema Eksperimen Bertahap

Untuk mencapai target performa yang ditetapkan (WER di bawah 30% dan CER di bawah 10%), penelitian ini dilakukan melalui tiga tahap eksperimen yang bersifat kumulatif, di mana setiap tahap menambahkan satu jenis perbaikan di atas tahap sebelumnya. Skema ketiga tahap eksperimen tersebut dirangkum pada Tabel 3.5.

Tabel 3.5 Skema Konfigurasi Tiga Tahap Eksperimen

Konfigurasi	Tahap 1 (Baseline)	Tahap 2 (Regularisasi)	Tahap 3 (Dataset Diperluas)
Jumlah data latih	9.710	9.710	27.230
Dropout	0,1	0,3	0,3
Augmentasi data (-- augment)	Tidak aktif	Aktif	Aktif
Strategi decoding evaluasi	Greedy	Beam search (width=10)	Beam search (width=10)

Tahap 1 merepresentasikan kondisi baseline sebagaimana rancangan awal pada Sub-bab 3.4.4. Tahap 2 menambahkan regularisasi dropout yang lebih besar, augmentasi data audio (random gain, penambahan derau Gaussian (derau acak berdistribusi normal), serta SpecAugment berupa time dan frequency masking), dan strategi decoding beam search tanpa language model eksternal. Tahap 3 mempertahankan seluruh konfigurasi Tahap 2, namun dilatih menggunakan dataset hasil perluasan sebagaimana dijelaskan pada Sub-bab 3.2.2. Hasil lengkap dari ketiga tahap eksperimen ini disajikan dan dianalisis pada Bab IV.


Ketiga jenis augmentasi yang diterapkan pada Tahap 2 dapat diringkas sebagai berikut. *Random gain* mengubah tingkat kenyaringan rekaman secara acak dalam rentang tertentu, sehingga model tidak terpaku pada volume rekaman dan tetap mengenali ucapan yang direkam terlalu pelan maupun terlalu keras. Penambahan derau Gaussian menyisipkan derau acak berdistribusi normal berdaya rendah ke dalam gelombang audio, sehingga model terbiasa menghadapi rekaman yang tidak sepenuhnya bersih. Adapun *SpecAugment* bekerja bukan pada gelombang audio melainkan pada Mel-Spectrogram yang sudah terbentuk, yaitu dengan menutup (*masking*) beberapa pita frekuensi dan beberapa rentang waktu secara acak, sehingga model dipaksa menyimpulkan bagian yang tertutup dari konteks di sekitarnya dan tidak bergantung pada satu pita frekuensi tertentu saja (Park et al., 2019).

Ketiga augmentasi tersebut hanya diterapkan pada data latih dan dijalankan secara acak setiap kali sebuah rekaman dibaca, sehingga model praktis tidak pernah menerima versi yang sama persis dari satu rekaman pada dua *epoch* yang berbeda. Data validasi dan data uji tidak diaugmentasi sama sekali agar hasil pengukuran tetap mencerminkan kondisi rekaman apa adanya.

3.5. Gambaran Umum Sistem yang Akan Dibangun

3.5.1. Metode Penelitian / Alur Kerja Sistem

Alur kerja sistem secara keseluruhan dalam melakukan penelitian ini diilustrasikan melalui flowchart pada Gambar 3.2.




Gambar 3.2 Flowchart Proses Kerja Sistem

Berdasarkan flowchart pada Gambar 3.2, tahapan proses metode penelitian yang dilakukan dijelaskan secara mendalam sebagai berikut

- **Muat Dataset:** Sistem membaca berkas audio (.wav) beserta label transkripsinya dari file *train.tsv* / *dev.tsv* pada korpus Mozilla Common Voice Bahasa Indonesia.
- **Validasi Dataset:** Sistem memeriksa validitas tiap baris data pada berkas .tsv, yaitu memastikan kolom *path* dan *sentence* tidak kosong serta menghasilkan teks yang tidak kosong setelah normalisasi. Baris data yang tidak valid dibuang dari daftar pemrosesan, sedangkan data yang valid diteruskan ke tahap *Pre-processing*.
- **Pre-processing:** Sinyal audio dinormalisasi (label diubah ke huruf kecil, tanda baca dihapus) dan diekstraksi menjadi representasi *Mel-Spectrogram*.
- **Pembagian Dataset:** Data hasil pra-pemrosesan dibagi menjadi data latih (*train*), data validasi (*dev*), dan data uji (*test*).
- **Bangun Arsitektur CRNN:** Model dibangun menggunakan pustaka PyTorch dalam dua skenario lapisan rekuren, yaitu *Bidirectional GRU* (BiGRU) dan *Bidirectional LSTM* (BiLSTM).
- **Pelatihan Model:** Kedua skenario dilatih secara terpisah hingga maksimum 50 *epoch*, dengan mekanisme *early stopping* apabila *validation* WER tidak membaik selama 5 *epoch* berturut-turut.
- **Evaluasi Model:** Model yang telah dilatih diuji pada data uji untuk menghitung *Word Error Rate* (WER) dan *Character Error Rate* (CER), sebagai dasar perbandingan kinerja BiGRU dan BiLSTM.

3.5.2. Arsitektur Sistem

Sistem dibangun menggunakan arsitektur gabungan (hibrida) untuk menangkap fitur spasial dan temporal dari data audio secara end-to-end. Berbeda dengan diagram alur proses biasa, Gambar 3.3 menggambarkan blok arsitektur beserta komponen-komponen penyusunnya secara eksplisit, mulai dari lapisan konvolusi di dalam blok CNN, mekanisme forward dan backward pass di dalam blok rekuren Bidirectional, hingga lapisan proyeksi linear sebelum tahap CTC Decoding.



Gambar 3.3 Blok Diagram Arsitektur CRNN-CTC

Berdasarkan diagram di atas, alur pemrosesan data melewati serangkaian tahapan komputasi sebagai berikut:

- **Input Audio (.wav):** Tahap penerimaan data sinyal audio digital. Sinyal dibaca untuk mendapatkan nilai amplitudo dan dikonversi ke dalam format mono dengan frekuensi sampling 16.000 Hz.
- **Ekstraksi Mel-Spectrogram:** Mengubah sinyal dari domain waktu menjadi domain frekuensi visual (2D). Gambar spektrogram ini merepresentasikan intensitas suara (dalam Desibel) pada berbagai tingkat frekuensi seiring

berjalannya waktu.

- **Blok CNN (Ekstraksi Fitur Spasial):** Tersusun atas tiga blok konvolusi berurutan (32→64→128 kanal), masing-masing berupa komponen *Conv2D* + *BatchNorm* + *ReLU* untuk memindai pola lokal tingkat tinggi (nada dan bentuk dasar fonem). Komponen *MaxPooling2D* (kernel 2×1) disisipkan setelah blok konvolusi pertama dan kedua untuk mereduksi dimensi frekuensi tanpa mengubah dimensi waktu, sehingga resolusi temporal tetap terjaga untuk pelabelan CTC. Blok CNN ditutup dengan komponen *Dropout* untuk mengurangi risiko *overfitting*.
- **Reshape ke Sequence Features:** Keluaran peta fitur dari blok CNN disusun ulang (*flatten*) menjadi representasi sekuensial berdimensi waktu, agar dapat diproses oleh lapisan rekuren pada tahap berikutnya.
- **Blok Rekuren BiGRU / BiLSTM (Perekaman Konteks Waktu Dua Arah):** Fitur sekuensial diproses secara paralel oleh komponen *forward pass* (membaca urutan dari masa lalu ke masa kini) dan komponen *backward pass* (membaca urutan dari masa depan ke masa kini). Kedua keluaran tersebut kemudian digabungkan pada komponen *concatenate* sehingga konteks kalimat dipahami secara utuh dari dua arah sekaligus. Konfigurasi layer pada blok ini yang membedakan skenario BiGRU dan skenario BiLSTM.
- **Blok CTC (Penyelarasan Teks):** Terdiri atas komponen *Linear* + *Softmax* yang mengonversi keluaran lapisan rekuren menjadi skor probabilitas untuk setiap karakter pada tiap *frame*, dilanjutkan komponen *CTC Decoding* yang menyisipkan karakter kosong (*blank token*) serta menghapus prediksi huruf yang berulang secara otomatis.
- **Output Teks Transkripsi:** Tahap akhir yang mengambil probabilitas tertinggi dari urutan karakter yang telah dirapikan, menghasilkan teks transkripsi akhir dari ucapan yang diucapkan.

3.5.3. Perbandingan Varian Model RNN

Pada penelitian ini, dilakukan komparasi terhadap dua varian arsitektur RNN berbasis Bidirectional untuk mengetahui efektivitasnya dalam mengenali pola

akustik bahasa Indonesia. Perbedaan mendasar dari kedua varian tersebut disajikan pada Tabel 3.6 berikut:

Tabel 3.6 Perbandingan Arsitektur Layer BiGRU dan BiLSTM

Nama Model	Arah Pemrosesan	Mekanisme Gerbang (Gates)	Karakteristik Utama
BiGRU	<i>Bidirectional</i>	2 Gates (<i>Update, Reset</i>)	Menangkap konteks sebelum dan sesudah ucapan.
BiLSTM	<i>Bidirectional</i>	3 Gates (<i>Input, Forget, Output</i>)	Konteks paling lengkap, kebutuhan komputasi paling tinggi.

Pengujian terhadap kedua varian arsitektur ini dilakukan untuk membuktikan secara empiris apakah kompleksitas struktur *layer* dan mekanisme gerbang berbanding lurus dengan kejelasan transkripsi fonetik yang dihasilkan, serta bagaimana pengaruhnya terhadap efisiensi waktu komputasi sistem .

- **Model BiGRU (*Bidirectional Gated Recurrent Unit*):** Memproses data dalam dua arah secara bersamaan (dari masa lalu ke masa depan, dan sebaliknya) menggunakan mekanisme gerbang pembaruan (*update gate*) dan gerbang reset (*reset gate*). Dengan menggabungkan dua keluaran arah pemrosesan pada setiap *time-step*, model mampu menangkap konteks kalimat secara lebih utuh dibandingkan varian searah, sembari tetap mempertahankan keunggulan efisiensi parameter dan kecepatan konvergensi khas arsitektur GRU dibandingkan keluarga LSTM.
- **Model BiLSTM (*Bidirectional Long Short-Term Memory*):** Menerapkan mekanisme gerbang memori yang lebih kompleks (*input, output, dan forget gate*) dalam dua arah pemrosesan sekaligus. Struktur tiga gerbang pada tiap arah memungkinkan model mengekstraksi informasi temporal yang paling komprehensif, baik dari konteks sebelum maupun sesudah kata yang diucapkan, namun dengan konsekuensi jumlah parameter dan kebutuhan komputasi serta waktu pelatihan yang paling tinggi di antara kedua varian yang diuji.

Sistem membandingkan kedua varian model tersebut secara kuantitatif berdasarkan evaluasi tingkat kesalahan prediksi (*Word Error Rate* dan *Character Error Rate*) serta efisiensi waktu pemrosesan selama masa pelatihan.

BAB IV

PERANCANGAN DAN IMPLEMENTASI SISTEM

4.1. Implementasi Lingkungan Pengembangan

Implementasi sistem pengenalan ucapan (*Automatic Speech Recognition/ASR*) berbasis arsitektur CRNN-CTC pada penelitian ini dilakukan menggunakan bahasa pemrograman *Python* dengan *framework Deep Learning* PyTorch, dijalankan pada *environment* virtual Anaconda bernama *skripsi_asr*. Proses komputasi, khususnya pada tahap pelatihan (*training*), memanfaatkan akselerasi GPU (CUDA) untuk mempercepat komputasi tensor pada lapisan konvolusi dan lapisan rekuren.

Struktur proyek disusun secara modular agar setiap tahapan proses dapat diuji secara terpisah. Tabel 4.1 menyajikan pemetaan modul program terhadap fungsinya masing-masing dalam alur sistem.

Tabel 4.1 Struktur dan Fungsi Modul Program

Nama Berkas	Fungsi dalam Sistem
dataset.py	Memuat & memvalidasi baris data dari berkas .tsv (path & teks), normalisasi teks, serta ekstraksi fitur Mel-Spectrogram (kelas CommonVoiceDataset dan MelSpecConfig).
model.py	Mendefinisikan arsitektur jaringan CRNNCTC beserta kelas konfigurasi ModelConfig (parameter rnn_type, rnn_hidden, rnn_layers, dropout).
text.py	Normalisasi teks (lowercasing dan penyaringan karakter), pembangunan kamus karakter (character vocabulary), serta fungsi encoding dan decoding CTC greedy (kelas Vocab).
metrics.py	Implementasi perhitungan metrik evaluasi Word Error Rate (WER) dan Character Error Rate (CER).

Nama Berkas	Fungsi dalam Sistem
ctc_decode.py	Implementasi beam search decoding untuk mengubah keluaran model menjadi teks pada tahap evaluasi akhir.
split_dataset.py	Membagi data menjadi subset latih, validasi, dan uji dengan rasio 80:10:10 (dipakai pada Tahap 1 dan Tahap 2).
split_validated.py	Membagi ulang seluruh data tervalidasi dengan rasio 90:5:5 (dipakai pada Tahap 3).
train.py	Menjalankan proses pelatihan model: loop epoch, perhitungan loss, scheduler, checkpointing, dan early stopping.
evaluate_test.py	Memuat model tersimpan (best.pt) untuk evaluasi akhir pada data uji (test set) menggunakan beam search decoding, sekaligus mengukur waktu inferensi model.
buat_semua_grafik.py	Membangkitkan visualisasi grafik perbandingan hasil pelatihan dan pengujian antara skenario BiGRU dan BiLSTM.
buat_melspec.py	Membangkitkan visualisasi Mel-Spectrogram dari satu berkas audio contoh sebagai ilustrasi tahap ekstraksi fitur (Gambar 4.1).
buat_grafik_416_test.py	Membangkitkan Gambar 4.16 versi test set (ringkasan perbandingan WER dan CER pada tiga tahap eksperimen).
infer.py	Melakukan inferensi satu berkas audio menggunakan checkpoint model tersimpan, dengan pilihan greedy atau beam search decoding (default beam, lebar 10). Kamus karakter dan konfigurasi Mel-Spectrogram dimuat langsung dari checkpoint sehingga pra-pemrosesan identik dengan saat pelatihan. Berfungsi sebagai antarmuka praktis sistem untuk transkripsi berkas tunggal.


Nama Berkas	Fungsi dalam Sistem
buat_tahapan_melspec.py	Membangkitkan visualisasi tahapan pembentukan Mel-Spectrogram (gelombang audio, spektrogram STFT, spektrogram desibel, dan Mel-Spectrogram) serta bank filter mel sebagai ilustrasi landasan teori (Gambar 2.1 dan Gambar 2.2).
buat_tabel_token.py	Membangun ulang kamus karakter dari data latih menggunakan fungsi yang sama dengan pipeline pelatihan, lalu membangkitkan tabel 30 token beserta ID-nya (Tabel 4.3).
buat_tabel_contoh_t3.py	Mengambil sejumlah kalimat acak dari data uji Tahap 3 dengan seed tetap, menjalankan kedua model menggunakan beam search decoding, lalu membangkitkan tabel perbandingan teks ground truth dan hasil prediksi beserta WER dan CER per kalimat (Tabel 4.11 dan Tabel 4.12).
demo_9_rekaman.py	Menjalankan demo inferensi terkendali pada sembilan rekaman suara pribadi yang dibagi menjadi tiga kelompok (kalimat data latih, data uji, dan karangan sendiri), menghitung WER dan CER per berkas serta rekapitulasi per kelompok (Tabel 4.17 sampai Tabel 4.19 dan Gambar 4.17).
konversi_wav.py	Mengonversi berkas audio hasil perekaman ke format WAV mono 16.000 Hz agar sesuai dengan format masukan yang digunakan seluruh pipeline penelitian.

Dataset yang digunakan bersumber dari korpus Mozilla Common Voice Bahasa Indonesia (cv-id), yang telah dibagi menjadi tiga subset independen dengan skrip `split_dataset.py` (rasio 80:10:10). Perlu dicatat bahwa pembagian inilah yang digunakan pada eksperimen Tahap 1 dan Tahap 2. Pada Tahap 3, dataset dibagi ulang menggunakan skrip `split_validated.py` dengan rasio 90:5:5 sebagaimana diuraikan pada Bab III. Rincian pembagian Tahap 1 dan Tahap 2 adalah `train.tsv` (data latih, 9.710 sampel), `dev.tsv` (data validasi selama pelatihan, 1.213 sampel), dan `test.tsv` (data uji akhir, 1.215 sampel) yang sama sekali tidak dilibatkan dalam proses pelatihan maupun penyetelan hyperparameter, sehingga hasil evaluasinya mencerminkan kemampuan generalisasi model terhadap data baru.

4.2. Implementasi Ekstraksi Fitur Mel-Spectrogram

Sebelum masuk ke tahap pelatihan, setiap berkas audio (.wav) terlebih dahulu diubah dari representasi domain waktu menjadi representasi domain frekuensi berupa *Mel-Spectrogram*, sebagaimana dijelaskan pada Landasan Teori (Bab II). Proses ini diimplementasikan pada kelas *MelSpecConfig* di dalam *dataset.py*, yang memuat parameter ekstraksi seperti frekuensi sampling 16.000 Hz dan jumlah pita Mel (*n_mels*) yang menjadi tinggi kanal masukan bagi blok CNN.

Gambar 4.1 menunjukkan hasil visualisasi Mel-Spectrogram dari salah satu rekaman uji berdurasi sekitar 4,9 detik. Bagian hening pada awal dan akhir rekaman dipangkas semata-mata agar bagian ucapan tampak lebih jelas pada gambar; pemangkasan ini tidak diterapkan pada pipeline pelatihan maupun evaluasi. Pola garis horizontal yang rapat pada rentang 250 hingga 1.000 Hz merupakan harmonik pita suara, sedangkan bagian yang hampir seragam gelap menunjukkan jeda hening antar kata.



Gambar 4.1 Visualisasi Ekstraksi Fitur Mel-Spectrogram (sumbu horizontal: waktu dalam detik; sumbu vertikal: frekuensi dalam skala Mel; intensitas warna: energi dalam desibel)

Perlu ditegaskan bahwa Mel-Spectrogram memuat tiga besaran sekaligus pada satu bidang dua dimensi. Sumbu horizontal menyatakan waktu, sumbu vertikal menyatakan frekuensi dalam skala Mel, sedangkan besaran ketiga yaitu intensitas energi dipetakan ke dalam gradasi warna. Batang warna (colorbar) di sisi kanan gambar berfungsi sebagai legenda pemetaan warna terhadap nilai energi dalam satuan desibel, sehingga bukan merupakan sumbu kedua. Warna gelap menandakan energi rendah dan warna terang menandakan energi tinggi. Nilai

desibel bersifat relatif terhadap amplitudo tertinggi pada rekaman, dengan batas bawah 80 dB di bawah nilai puncak sesuai parameter `top_db` pada modul `dataset.py`. Visualisasi ini menampilkan representasi log-mel sebelum tahap normalisasi mean-standar deviasi per-ucapan, agar skala intensitasnya tetap dapat dibaca secara fisik; pada proses pelatihan, representasi tersebut selanjutnya dinormalisasi sebagaimana diimplementasikan pada modul `dataset.py`.

4.3. Implementasi Arsitektur Model dan Parameter Pelatihan

Arsitektur CRNN-CTC yang telah dirancang pada Bab III (Gambar 3.3) diimplementasikan pada kelas *CRNNCTC* di berkas *model.py*. Untuk mendukung dua skenario pengujian, kelas *ModelConfig* menyediakan parameter *rnn_type* yang dapat diisi dengan nilai *"bigru"* atau *"bilstm"*, sehingga kedua model dapat dibangun dari basis kode yang identik, dan perbedaan performa yang diperoleh nantinya murni disebabkan oleh perbedaan mekanisme gerbang (*gate*) pada lapisan rekuren, bukan oleh perbedaan implementasi lainnya.

Kedua skenario dijalankan secara terpisah melalui antarmuka baris perintah (*command-line*) pada *train.py*, misalnya `python train.py --data_dir ../02_dataset/cv-id --rnn_type bigru`. Realisasi parameter pelatihan pada kode program ditunjukkan pada Tabel 4.2, yang telah sesuai dengan rancangan pada Sub-bab 3.4.4.

Tabel 4.2 Realisasi Parameter Pelatihan pada Kode Program

Parameter	Nilai Implementasi
Optimizer	AdamW ($lr = 3 \times 10^{-4}$, $weight_decay = 1 \times 10^{-2}$)
Fungsi Loss	CTCLoss (blank = id token kosong, zero_infinity = True)
Batch Size	16
Lapisan Rekuren	3 lapisan stacked, hidden_size = 256, dropout = 0,1
Gradient Clipping	Maksimum norma 5,0
Learning Rate Scheduler	ReduceLROnPlateau (factor = 0,5, patience = 2, berbasis loss validasi)
Maksimum Epoch	50, dengan mekanisme resume training dari checkpoint terakhir
Early Stopping	Patience = 5 epoch berbasis WER validasi

Sebagai catatan tambahan, *train.py* juga dilengkapi mekanisme *resume training* yang secara otomatis memuat *checkpoint* terakhir (*best.pt*) apabila proses pelatihan terhenti di tengah jalan (misalnya akibat perangkat mati mendadak), sehingga status *epoch* dan nilai WER terbaik dapat dilanjutkan tanpa mengulang pelatihan dari awal. Fitur ini merupakan penyempurnaan teknis di luar rancangan awal yang ditambahkan untuk menjaga keandalan proses eksperimen.


4.4. Proses dan Hasil Pelatihan Model

Proses pelatihan dilakukan secara terpisah untuk kedua skenario dengan ukuran kamus karakter (*vocabulary*) sebanyak 30 token, yang terdiri atas 26 huruf alfabet dasar (a–z), karakter spasi, tanda apostrof (') yang muncul pada sebagian kalimat korpus, serta dua token khusus yaitu *blank* untuk keperluan penyelarasan CTC dan *unknown* untuk menampung karakter di luar kamus. Pada setiap akhir *epoch*, model dievaluasi terhadap data validasi (*dev.tsv*) untuk menghasilkan nilai loss, WER, dan CER pada data validasi, yang digunakan sebagai acuan penyimpanan *checkpoint* terbaik (*best.pt*) serta pemicu mekanisme early stopping.

Kamus karakter tersebut dibangun secara otomatis dari seluruh kalimat pada data latih oleh fungsi *build_char_vocab_from_texts* pada berkas *text.py*, terdiri atas dua token khusus, yaitu <blank> (token kosong untuk CTC) dan <unk> (karakter tak dikenal), diikuti token spasi, apostrof, serta 26 huruf a–z. Kamus ini turut disimpan di dalam *checkpoint* sehingga pemetaan ID token pada saat evaluasi dijamin identik dengan saat pelatihan. Rincian ke-30 token beserta ID-nya disajikan pada Tabel 4.3.

Tabel 4.3 Kamus Karakter (Vocabulary) 30 Token Hasil Pembangunan dari Data Latih

ID	Token	ID	Token	ID	Token
0	<blank>	10	g	20	q
1	<unk>	11	h	21	r
2	(spasi)	12	i	22	s
3	' (apostrof)	13	j	23	t
4	a	14	k	24	u
5	b	15	l	25	v
6	c	16	m	26	w
7	d	17	n	27	x
8	e	18	o	28	y
9	f	19	p	29	z



Gambar 4.2 Perbandingan Validation Loss Tahap 1 (BiGRU vs BiLSTM)

Berdasarkan Gambar 4.2, kedua model menunjukkan pola konvergensi yang serupa: *loss* validasi turun tajam pada 10 *epoch* pertama, kemudian melandai dan mencapai titik terendah pada *epoch* 12 untuk BiGRU dan *epoch* 13 untuk BiLSTM, sebelum akhirnya sedikit meningkat kembali menjelang *epoch* akhir. Titik penanda pada kedua kurva menunjukkan posisi *checkpoint* terbaik masing-masing model — BiLSTM pada *epoch* 23 (*loss* 0,7992) dan BiGRU pada *epoch* 28 (*loss* 0,8606) — yang dipilih berdasarkan nilai WER validasi terendah, bukan berdasarkan *loss*, sehingga letaknya tidak berimpit dengan titik terendah kurva *loss*. Kenaikan tipis pada *loss* setelah titik terendah tersebut merupakan indikasi awal *overfitting* ringan, yang kemudian berhasil ditangani oleh mekanisme *early stopping* sehingga pelatihan dihentikan secara otomatis sebelum performa model menurun lebih jauh. Kurva BiLSTM (garis oranye) secara konsisten berada di bawah kurva BiGRU (garis biru) setelah *epoch* ke-10, yang mengindikasikan proses belajar yang sedikit lebih efisien.

Ringkasan hasil akhir proses pelatihan (berdasarkan metrik validasi) untuk kedua skenario disajikan pada Tabel 4.4.

Tabel 4.4 Ringkasan Hasil Pelatihan Tahap 1 (Metrik Validasi)

Keterangan	BiGRU	BiLSTM
Epoch pelatihan berhenti (early stopping)	33	28
Epoch dengan checkpoint terbaik	28	23
Loss Validasi terbaik	0,8606	0,7992
WER Validasi terbaik	59,99%	56,32%
CER Validasi terbaik	16,58%	15,63%
Estimasi waktu komputasi pelatihan	± 2 jam 16 menit	± 1 jam 34 menit


Selisih antara *epoch checkpoint* terbaik (28 untuk BiGRU dan 23 untuk BiLSTM) dan titik terendah kurva *loss* (*epoch* 12–13) terjadi karena pemilihan *checkpoint* didasarkan pada WER validasi, bukan *loss*. Setelah *loss* mencapai titik terendahnya, kualitas transkripsi hasil *decoding* masih terus membaik, sehingga WER validasi baru mencapai nilai terbaiknya beberapa *epoch* kemudian. Konsistensi mekanisme ini juga terlihat pada baris pertama Tabel 4.4: pelatihan berhenti tepat lima *epoch* setelah *checkpoint* terbaik ($28+5=33$ dan $23+5=28$), sesuai nilai *patience* pada mekanisme *early stopping*.

4.5. Hasil Pengujian Model pada Data Uji (Test Set)


Sesuai dengan rancangan alur kerja sistem pada Gambar 3.2 tahap Evaluasi Model, setelah proses pelatihan selesai, *checkpoint* terbaik dari masing-masing skenario diuji ulang secara terpisah menggunakan *evaluate_test.py* terhadap data uji (*test.tsv*) yang berisi 1.215 sampel dan tidak pernah dilihat oleh model selama proses pelatihan maupun validasi. Hasil pengujian ini merepresentasikan estimasi paling objektif terhadap kemampuan generalisasi kedua model.

Tabel 4.5 Hasil Evaluasi Tahap 1 pada Data Uji (Test Set)


Metrik	BiGRU	BiLSTM
Test Loss	0,7938	0,7306
Test WER	59,20%	54,82%
Test CER	15,92%	14,63%
Waktu evaluasi (1.215 data uji)	16,91 detik	14,92 detik



Gambar 4.3 Perbandingan Final Word Error Rate (WER) Tahap 1



Gambar 4.4 Perbandingan Final Character Error Rate (CER) Tahap 1



Gambar 4.5 Perbandingan Waktu Evaluasi pada 1.215 Data Uji

Hasil pada Tabel 4.5 menunjukkan bahwa nilai WER dan CER pada data uji sedikit lebih rendah dibandingkan nilai dev terbaik pada Tabel 4.4 untuk kedua model (BiGRU: WER validasi 59,99% menjadi WER uji 59,20%; BiLSTM: WER validasi 56,32% menjadi WER uji 54,82%). Hal ini mengindikasikan bahwa model tidak mengalami overfitting yang signifikan terhadap data validasi, karena performanya tetap konsisten atau bahkan sedikit lebih baik ketika diuji pada data yang benar-benar baru.

4.6. Analisis Perbandingan Head-to-Head BiGRU dan BiLSTM

Merujuk pada rumusan pengujian pada Sub-bab 3.5.3, perbandingan *head-to-head* dilakukan untuk membuktikan secara empiris apakah kompleksitas mekanisme gerbang pada BiLSTM (tiga gerbang: *input*, *forget*, *output*) memberikan keunggulan akurasi dibandingkan BiGRU (dua gerbang: *update*, *reset*), serta bagaimana pengaruhnya terhadap efisiensi waktu komputasi.

Dari sisi akurasi, hasil pengujian pada Tabel 4.5 secara konsisten menunjukkan BiLSTM unggul dibandingkan BiGRU, dengan selisih WER sebesar 4,38 poin persentase (59,20% → 54,82%) dan selisih CER sebesar 1,29 poin persentase (15,92% → 14,63%). Temuan ini sejalan dengan hipotesis awal pada Bab III, di mana gerbang *forget* pada BiLSTM memungkinkan model mengatur informasi konteks jangka panjang secara lebih selektif dibandingkan mekanisme *reset gate* pada GRU, sehingga lebih efektif dalam menangkap ketergantungan antar-*frame* pada sinyal ucapan Bahasa Indonesia.

Keunggulan tersebut dapat dijelaskan lebih rinci dari tiga sifat arsitektur LSTM. Pertama, LSTM memiliki jalur memori terpisah berupa *cell state* yang mengalir sepanjang urutan dengan gangguan minimal, yaitu hanya dikalikan gerbang *forget* dan ditambah keluaran gerbang *input*. GRU tidak memiliki jalur terpisah semacam itu; memorinya menyatu dengan *hidden state* yang sekaligus menjadi keluaran pada setiap langkah waktu. Akibatnya GRU harus memakai satu vektor yang sama untuk dua keperluan sekaligus, yaitu menyimpan konteks jangka panjang dan menghasilkan keluaran saat ini, sedangkan LSTM dapat memisahkan keduanya.

Kedua, LSTM memisahkan keputusan mengenai apa yang dilupakan dan apa yang disimpan ke dalam dua gerbang yang berdiri sendiri, yaitu *forget gate* dan *input gate*. Pada GRU kedua keputusan tersebut digabung ke dalam satu *update gate* sehingga bersifat saling meniadakan: menyerap informasi baru sebanyak porsi tertentu berarti melupakan informasi lama sebanyak porsi yang sama. Pada sinyal ucapan, kedua keputusan itu tidak selalu berjalan beriringan, sebab model kerap perlu menyerap ciri akustik baru sambil tetap mempertahankan konteks kata yang sedang berlangsung. Pemisahan gerbang pada LSTM memberikan keleluasaan yang lebih besar untuk hal tersebut.

Ketiga, konsekuensi langsung dari kedua sifat di atas adalah kapasitas parameter yang lebih besar. Pada konfigurasi yang digunakan penelitian ini, lapisan rekuren BiLSTM memuat sekitar 33% parameter lebih banyak dibandingkan BiGRU, sebagaimana dirinci pada Sub-bab 4.10. Kapasitas tambahan tersebut memberi keuntungan selama data latih masih memadai untuk mengisinya. Pola ini terlihat pada hasil penelitian: selisih WER antara kedua model menyempit tajam ketika dataset diperluas, yaitu dari 6,10 poin persentase pada Tahap 2 menjadi 1,77 poin persentase pada Tahap 3, padahal seluruh konfigurasi selain jumlah data dibuat sama. Dengan kata lain, keunggulan kapasitas BiLSTM justru paling terasa ketika data latih terbatas.

Pola yang sama juga dilaporkan pada literatur. Shewalkar et al. (2019), yang membandingkan RNN, LSTM, dan GRU pada tugas pengenalan ucapan berbahasa Inggris, memperoleh hasil serupa: LSTM mencatat WER terbaik sementara GRU mencapai waktu optimasi yang lebih singkat dengan WER yang berdekatan.

Kesesuaian ini menunjukkan bahwa temuan pada penelitian ini bukan kekhususan Bahasa Indonesia, melainkan konsekuensi dari perbedaan struktur kedua sel rekuren.

Agar perbedaan karakteristik kedua arsitektur beserta akibatnya dapat dibaca secara ringkas, seluruh uraian di atas dirangkum pada Tabel 4.6.

Tabel 4.6 *Ringkasan Perbedaan Karakteristik LSTM dan GRU beserta Implikasinya*

Aspek	LSTM	GRU	Implikasi pada Penelitian Ini
Jalur memori	Cell state terpisah dari hidden state	Memori menyatu dengan hidden state	LSTM dapat memisahkan penyimpanan konteks dari keluaran saat ini
Jumlah gerbang	3 gerbang: forget, input, output	2 gerbang: update, reset	Pada GRU, keputusan menyimpan dan melupakan saling meniadakan
Kelompok bobot per sel	4 kelompok	3 kelompok	Rasio parameter lapisan rekuren mendekati 4 berbanding 3
Parameter lapisan rekuren	8.925.184	6.693.888	BiLSTM memiliki 33,3% parameter lebih banyak
WER data uji Tahap 3	26,36%	28,13%	BiLSTM unggul 1,77 poin persentase
CER data uji Tahap 3	6,59%	7,01%	BiLSTM unggul 0,42 poin persentase
Waktu inferensi Tahap 3	10,52 detik	9,35 detik	BiGRU sekitar 11% lebih cepat

Tiga baris pertama pada Tabel 4.6 menjelaskan perbedaan struktural, sedangkan empat baris berikutnya menunjukkan akibatnya yang terukur. Pola yang terbaca adalah bahwa keunggulan BiLSTM pada akurasi berasal dari kapasitas dan keleluasaan gerbangnya, sementara keunggulan BiGRU pada kecepatan berasal dari struktur selnya yang lebih ringkas.

Adapun contoh konkret jenis kesalahan yang dihasilkan kedua model disajikan pada Sub-bab 4.8, menggunakan model hasil Tahap 3 sebagai konfigurasi akhir penelitian.

Dari sisi efisiensi waktu, hasil justru menunjukkan pola yang berlawanan dengan asumsi umum bahwa arsitektur dengan gerbang lebih kompleks akan membutuhkan waktu lebih lama. Pada penelitian ini, BiLSTM mencapai kondisi early stopping lebih cepat, yaitu pada epoch ke-28 dibandingkan BiGRU pada epoch ke-33 (Tabel 4.4), serta membutuhkan waktu evaluasi pada data uji yang lebih singkat, yaitu 14,92 detik dibandingkan 16,91 detik pada BiGRU (Tabel 4.5). Hal ini dapat dijelaskan karena BiLSTM mencapai titik konvergensi (WER validasi terendah) yang lebih baik dalam jumlah epoch yang lebih sedikit, sehingga meskipun komputasi per-epoch pada BiLSTM sedikit lebih berat secara teoritis akibat jumlah parameter yang lebih banyak, total waktu pelatihan keseluruhan justru lebih rendah karena jumlah epoch yang dibutuhkan hingga early stopping juga lebih sedikit.


Dengan demikian, dapat disimpulkan bahwa pada kasus dan skala dataset yang digunakan dalam penelitian ini, BiLSTM memberikan performa yang lebih unggul dibandingkan BiGRU baik dari sisi akurasi pengenalan teks (WER dan CER) maupun dari sisi efisiensi waktu komputasi secara keseluruhan (jumlah *epoch* hingga konvergensi dan waktu inferensi), sehingga *trade-off* kompleksitas terhadap efisiensi yang diasumsikan pada Bab III tidak sepenuhnya terbukti pada konteks penelitian ini.

Hasil pada Sub-bab 4.4 hingga 4.6 di atas merupakan hasil eksperimen Tahap 1 (baseline), sesuai skema pada Tabel 3.5. Dua sub-bab berikut (4.7 dan 4.8) menyajikan hasil eksperimen Tahap 2 dan Tahap 3 yang dilakukan untuk memperbaiki performa model.

4.7. Tahap 2: Eksperimen dengan Regularisasi, Augmentasi Data, dan Beam Search Decoding


Merujuk pada keterbatasan yang teridentifikasi pada Sub-bab 4.13 (Pembahasan Umum dan Keterbatasan Sistem), khususnya nilai WER yang masih tinggi pada Tahap 1, dilakukan eksperimen Tahap 2 dengan tiga perubahan konfigurasi sekaligus terhadap kedua model: (1) peningkatan dropout dari 0,1 menjadi 0,3 untuk regularisasi yang lebih kuat, (2) pengaktifan augmentasi data

audio (--augment) yang sebelumnya tersedia namun tidak digunakan, dan (3) penggantian strategi decoding evaluasi dari greedy menjadi beam search dengan lebar beam 10, diimplementasikan pada modul `ctc_decode.py`.




Gambar 4.6 Perbandingan Validation Loss Tahap 2 (BiGRU vs BiLSTM)

Gambar 4.6 menunjukkan kurva validation loss Tahap 2 untuk kedua model. BiGRU menghentikan pelatihan lebih awal melalui mekanisme early stopping pada epoch ke-43, sedangkan BiLSTM menyelesaikan seluruh 50 epoch tanpa terpicu early stopping, mengindikasikan model masih berpotensi membaik apabila jumlah epoch ditambah.



Gambar 4.7 Perbandingan Word Error Rate (WER) Tahap 2



Gambar 4.8 Perbandingan Character Error Rate (CER) Tahap 2

Ringkasan hasil terbaik (berdasarkan metrik validasi) pada eksperimen Tahap 2 disajikan pada Tabel 4.7.

Tabel 4.7 Ringkasan Hasil Tahap 2 (Metrik Validasi)

Metrik	BiGRU	BiLSTM
Epoch Terbaik	38 (early stopping epoch 43)	50 (belum early stopping)
WER Validasi	49,53%	44,58%
CER Validasi	13,56%	11,87%


Dibandingkan hasil Tahap 1 (Tabel 4.4), kedua model menunjukkan peningkatan yang berarti: WER BiGRU turun dari 59,99% menjadi 49,53% (selisih 10,46 poin persentase), sedangkan WER BiLSTM turun dari 56,32% menjadi 44,58% (selisih 11,74 poin persentase). Pola BiLSTM tetap unggul dibandingkan BiGRU juga masih konsisten terjadi pada Tahap 2 ini. Meskipun terjadi peningkatan yang signifikan, nilai WER kedua model pada Tahap 2 masih berada di atas target penelitian (WER di bawah 30%), sehingga eksperimen dilanjutkan ke Tahap 3.

4.8. Tahap 3: Eksperimen dengan Perluasan Dataset


Eksperimen Tahap 3 mempertahankan seluruh konfigurasi Tahap 2 (dropout 0,3, augmentasi aktif, beam search decoding), namun dilatih menggunakan dataset hasil perluasan yang telah dijelaskan pada Sub-bab 3.2.2. Perbandingan ukuran dataset sebelum dan sesudah perluasan ditunjukkan kembali pada Tabel 4.8 sebagai konteks.

Tabel 4.8 Perbandingan Ukuran Dataset Tahap 1/2 dan Tahap 3


Subset	Tahap 1 dan 2	Tahap 3
Data Latih (Train)	9.710	27.230
Data Validasi	1.213	1.512
Data Uji (Test)	1.215	1.514
Total	12.138	30.256



Gambar 4.9 Perbandingan Validation Loss Tahap 3 (BiGRU vs BiLSTM)



Gambar 4.10 Perbandingan Word Error Rate (WER) Tahap 3



Gambar 4.11 Perbandingan Character Error Rate (CER) Tahap 3

Ringkasan hasil terbaik pada data validasi untuk Tahap 3 disajikan pada Tabel 4.9. BiLSTM mencapai WER validasi terbaik 27,04% pada epoch ke-49, sedangkan BiGRU mencapai WER validasi terbaik 28,25% pada epoch ke-50;

kedua model sama-sama menyelesaikan seluruh 50 epoch tanpa terpicu early stopping.


Tabel 4.9 Ringkasan Hasil Pelatihan Tahap 3 (Metrik Validasi)

Metrik	BiGRU	BiLSTM
Epoch Terbaik	50	49
WER Validasi	28,25%	27,04%
CER Validasi	7,28%	6,82%


Sebagai estimasi objektif kemampuan generalisasi model, checkpoint terbaik masing-masing skenario kemudian dievaluasi ulang menggunakan skrip `evaluate_test.py` terhadap data uji (`test.tsv`) hasil perluasan yang berisi 1.514 data dan sama sekali tidak dilibatkan dalam proses pelatihan maupun pemilihan checkpoint terbaik. Hasil evaluasi akhir ini disajikan pada Tabel 4.10.

Tabel 4.10 Hasil Evaluasi Akhir pada Test Set Tahap 3


Metrik	BiGRU	BiLSTM
Test Loss	0,2652	0,2609
Test WER	28,13%	26,36%
Test CER	7,01%	6,59%
Akurasi Kata	71,87%	73,64%
Akurasi Karakter	92,99%	93,41%



Gambar 4.12 Perbandingan Final Test Loss pada Test Set Tahap 3



Gambar 4.13 Perbandingan Final Word Error Rate (WER) pada Test Set Tahap 3



Gambar 4.14 Perbandingan Final Character Error Rate (CER) pada Test Set Tahap 3

Hasil pada Tabel 4.10 menunjukkan bahwa kedua model berhasil mencapai target performa yang ditetapkan pada awal penelitian, yaitu WER di bawah 30% dan CER di bawah 10%. BiLSTM mencapai WER 26,36% dan CER 6,59%, sementara BiGRU mencapai WER 28,13% dan CER 7,01%. Menariknya, nilai WER dan CER pada test set sedikit lebih rendah dibandingkan nilai dev terbaik pada Tabel 4.9 untuk kedua model, mengindikasikan model tidak mengalami overfitting terhadap data validasi meskipun dilatih dengan dataset yang jauh lebih besar. Pola BiLSTM unggul dibandingkan BiGRU juga tetap konsisten terjadi pada Tahap 3, sebagaimana telah teramati pada Tahap 1 dan Tahap 2 sebelumnya.

Apabila dinyatakan dalam bentuk akurasi, hasil akhir tersebut setara dengan akurasi kata 73,64% dan akurasi karakter 93,41% untuk BiLSTM, serta akurasi kata 71,87% dan akurasi karakter 92,99% untuk BiGRU.

Untuk memperjelas jenis kesalahan yang masih terjadi, Tabel 4.11 dan Tabel 4.12 menyajikan enam contoh perbandingan antara teks asli (*ground truth*) dan hasil prediksi kedua model pada data uji Tahap 3, beserta nilai WER dan CER

masing-masing kalimat. Contoh diambil secara acak dengan *seed* tetap sehingga pemilihannya dapat direproduksi.

Tabel 4.11 Contoh Perbandingan Teks Ground Truth dan Hasil Prediksi Model BiLSTM pada Data Uji Tahap 3

Status	Teks Asli (Ground Truth)	Teks Prediksi Model	WER	CER	Berkas Sumber
Tepat	pak lee berencana ada di jepang selama tiga tahun	pak lee berencana ada di jepang selama tiga tahun	0/9 = 0,00%	0/49 = 0,00%	common_voice_id_25165329.mp3
Keliru	hai pak tanaka selamat malam	saak pak tanaka seamat malam	2/5 = 40,00%	4/28 = 14,29%	common_voice_id_20957359.mp3
Tepat	tangan dan lengan mereka lurus dan tinggi	tangan dan lengan mereka lurus dan tinggi	0/7 = 0,00%	0/41 = 0,00%	common_voice_id_26206305.mp3
Tepat	ketika dia sampai stasiun keretanya telah berangkat	ketika dia sampai stasiun keretanya telah berangkat	0/7 = 0,00%	0/51 = 0,00%	common_voice_id_32647488.mp3
Keliru	semua anggota tidak menghadiri rapat kemarin	semua ang kota tidak menghadiri apa kemarin	4/6 = 66,67%	5/44 = 11,36%	common_voice_id_20954402.mp3
Keliru	ibu kimura memakai rok imut	ibu kimura memakai rok kimut	1/5 = 20,00%	1/27 = 3,70%	common_voice_id_21023584.mp3

Tabel 4.12 Contoh Perbandingan Teks Ground Truth dan Hasil Prediksi Model BiGRU pada Data Uji Tahap 3

Status	Teks Asli (Ground Truth)	Teks Prediksi Model	WER	CER	Berkas Sumber
Tepat	pak lee berencana ada di jepang selama tiga tahun	pak lee berencana ada di jepang selama tiga tahun	0/9 = 0,00%	0/49 = 0,00%	common_voice_id_25165329.mp3
Keliru	hai pak tanaka selamat malam	saa patanaka selamat malam	3/5 = 60,00%	4/28 = 14,29%	common_voice_id_20957359.mp3
Keliru	tangan dan lengan mereka lurus dan tinggi	tangan dan mengan mereka lurus dan tinggi	1/7 = 14,29%	1/41 = 2,44%	common_voice_id_26206305.mp3
Tepat	ketika dia sampai stasiun keretanya telah berangkat	ketika dia sampai stasiun keretanya telah berangkat	0/7 = 0,00%	0/51 = 0,00%	common_voice_id_32647488.mp3
Keliru	semua anggota tidak menghadiri rapat kemarin	semua angkota tidak menhadii apat kemarin	4/6 = 66,67%	5/44 = 11,36%	common_voice_id_20954402.mp3
Keliru	ibu kimura memakai rok imut	ibu kimura memakai rok kikut	1/5 = 20,00%	2/27 = 7,41%	common_voice_id_21023584.mp3

Dari enam contoh tersebut, BiLSTM menghasilkan tiga transkripsi yang tepat sepenuhnya, sedangkan BiGRU dua transkripsi. Pola ini konsisten dengan hasil evaluasi menyeluruh pada Tabel 4.10 yang menunjukkan keunggulan BiLSTM.

Kesalahan yang muncul dapat dikelompokkan menjadi tiga jenis. Pertama, kekeliruan membedakan fonem yang berdekatan, misalnya *lengan* menjadi *mengan* dan *selamat* menjadi *seamat*. Kedua, kesalahan penentuan batas kata, misalnya *anggota* menjadi *ang kota* pada BiLSTM dan *semua anggota* menjadi *semuaangkota* pada BiGRU. Ketiga, penyisipan karakter yang terbawa dari kata sebelumnya, misalnya *rok imut* menjadi *rok kimut* — bunyi /k/ pada akhir kata *rok* ikut terbaca sebagai awal kata berikutnya.

Setiap contoh pada Tabel 4.11 dan Tabel 4.12 dilengkapi kolom Berkas Sumber yang memuat nama berkas audio asli pada korpus Common Voice. Pencantuman ini dimaksudkan agar setiap pasangan teks acuan dan teks prediksi dapat ditelusuri kembali ke rekaman yang menjadi sumbernya, sehingga hasil pada kedua tabel tersebut dapat diperiksa ulang oleh pembaca. Keenam berkas tersebut berasal dari data uji Tahap 3, yaitu bagian korpus yang tidak pernah digunakan pada proses pelatihan maupun validasi.

Ketiga pola tersebut merupakan konsekuensi langsung dari pendekatan pengenalan pada tingkat karakter tanpa *language model* eksternal. Model hanya memetakan pola akustik menjadi urutan karakter tanpa memiliki pengetahuan kosakata maupun tata bahasa, sehingga tidak dapat mengoreksi ejaan atau menentukan batas kata berdasarkan konteks. Hal ini juga menjelaskan mengapa nilai CER selalu jauh lebih rendah daripada WER: satu karakter yang keliru sudah cukup membuat seluruh kata dihitung salah. Sebagai contoh, pada kalimat *ibu kimura memakai rok imut*, BiLSTM hanya keliru satu karakter dari 27 karakter (CER 3,70%), tetapi kesalahan itu membuat satu dari lima kata dinilai salah (WER 20,00%).

Ketiga jenis kesalahan tersebut dapat ditelusuri lebih jauh sampai ke sifat akustiknya. Pada jenis pertama, pasangan bunyi yang tertukar bukan pasangan sembarangan. Perubahan lengan menjadi mengan melibatkan bunyi /l/ dan /m/ yang sama-sama bersuara dan sama-sama memusatkan energinya pada pita frekuensi rendah, sehingga pola keduanya pada Mel-Spectrogram sangat mirip. Pada jenis kedua, hilangnya bunyi /l/ pada selamat menjadi seamat terjadi karena bunyi tersebut diapit dua vokal dan diucapkan sangat singkat, sehingga hanya menempati sedikit frame dan mudah tertelan oleh vokal di sekitarnya. Adapun jenis ketiga berkaitan dengan kenyataan bahwa dalam ucapan kontinu tidak terdapat jeda akustik yang menandai batas antar-kata. Spasi pada teks adalah kesepakatan penulisan, bukan bunyi, sehingga model harus menyimpulkan sendiri letak batas kata dari konteks yang dipelajarinya.

Perbandingan langsung antara kedua model pada kalimat yang sama juga memperlihatkan hal yang menarik. Pada kalimat *hai pak tanaka selamat malam*, BiLSTM dan BiGRU sama-sama mencatat CER 14,29%, artinya jumlah karakter

yang keliru pada keduanya persis sama, yaitu empat karakter. Namun nilai WER keduanya berbeda cukup jauh, yaitu 40,00% pada BiLSTM dan 60,00% pada BiGRU. Perbedaan tersebut muncul karena persebaran kesalahannya tidak sama: pada BiLSTM keempat karakter yang keliru terkumpul pada dua kata, sedangkan pada BiGRU tersebar ke tiga kata sehingga tiga kata sekaligus dihitung salah. Contoh ini menunjukkan bahwa keunggulan BiLSTM tidak selalu berupa jumlah karakter benar yang lebih banyak, melainkan juga kemampuan menahan kesalahan agar tidak merembet ke kata-kata di sekitarnya, yang sejalan dengan kapasitas memori konteksnya yang lebih besar.

Pola serupa terlihat pada kesalahan batas kata. Kata anggota diprediksi menjadi ang kota oleh BiLSTM dan semuaangkota oleh BiGRU. Kedua model gagal pada kata yang sama, yang menandakan kesulitannya bersumber dari sinyal audio dan bukan dari arsitektur. Namun bentuk kegagalannya berbeda: BiLSTM keliru menyisipkan satu batas kata, sedangkan BiGRU justru menghilangkan batas kata sebelumnya sehingga dua kata menyatu. Kesalahan BiGRU tersebut berdampak pada lebih banyak kata sekaligus, dan hal ini merupakan salah satu penyebab selisih WER antara kedua model tetap ada meskipun selisih CER-nya kecil.


Sebagai pelengkap terhadap keenam contoh di atas, seluruh 1.514 ucapan pada data uji Tahap 3 turut dianalisis secara agregat untuk mengetahui komposisi jenis kesalahannya. Pada BiGRU tercatat 2.776 kesalahan tingkat kata, terdiri atas 81,7% substitusi, 12,1% penghapusan, dan 6,2% penyisipan. Pada BiLSTM tercatat 2.601 kesalahan dengan komposisi 82,6% substitusi, 11,5% penghapusan, dan 5,9% penyisipan. Kemiripan komposisi tersebut mengandung makna tersendiri: BiLSTM tidak menghasilkan jenis kesalahan yang berbeda dari BiGRU, melainkan menghasilkan kesalahan yang sejenis dalam jumlah yang lebih sedikit, yaitu berkurang 175 kesalahan atau sekitar 6,3%. Dominasi substitusi yang mencapai lebih dari 81% juga sejalan dengan penjelasan sebelumnya, yaitu bahwa model pada umumnya berhasil menangkap keberadaan dan jumlah kata namun keliru pada identitas fonemnya.

Penelusuran terhadap pasangan kata yang paling sering tertukar memperkuat kesimpulan tersebut. Pada BiGRU, kekeliruan yang paling sering

muncul adalah pun menjadi apapun, karangan menjadi karengan, lalulintas menjadi lintas, diatas menjadi atas, dan bertahun-tahun menjadi tahun. Pada BiLSTM, yang paling sering adalah bahwa menjadi bawa, diatas menjadi atas, kami menjadi kamu, dan pun menjadi apapun. Dua pola tampak menonjol. Pertama, kesalahan batas kata pada kata majemuk dan kata berimbuhan, misalnya lalulintas, diatas, dan bertahun-tahun, yang seluruhnya kehilangan sebagian unsurnya karena model tidak mengenal aturan penulisan kata. Kedua, kekeliruan pada pasangan kata yang hanya berbeda satu vokal, misalnya kami menjadi kamu dan bahwa menjadi bawa, yang secara akustik memang sangat berdekatan. Pasangan diatas menjadi atas dan pun menjadi apapun muncul pada kedua model, sehingga menunjukkan bahwa sebagian kesulitan bersumber dari sifat sinyal audio dan cara penulisan kata itu sendiri, bukan dari kelemahan salah satu arsitektur.

Selain akurasi, penelitian ini juga mengukur kecepatan inferensi kedua model pada test set Tahap 3. Pengukuran difokuskan pada waktu forward pass model (bukan waktu decoding), karena proses decoding tidak dipengaruhi oleh pilihan arsitektur lapisan rekuren. Setiap model diukur sebanyak tiga kali, lalu diambil rata-ratanya untuk mengurangi pengaruh variasi beban sistem.

Hasil pengukuran menunjukkan BiGRU memiliki rata-rata waktu inferensi 9,35 detik, lebih cepat dibandingkan BiLSTM yang membutuhkan 10,52 detik untuk memproses 1.514 data uji, atau selisih sekitar 11%. Rentang ketiga pengukuran kedua model tidak saling tumpang tindih (BiGRU 9,18–9,45 detik; BiLSTM 10,26–10,66 detik), sehingga keunggulan kecepatan BiGRU bersifat konsisten. Hasil ini sesuai dengan teori: sel GRU hanya memiliki dua gerbang, sedangkan sel LSTM memiliki tiga gerbang, sehingga GRU melakukan komputasi yang lebih sedikit pada setiap langkah waktu. Perbandingan waktu inferensi disajikan pada Gambar 4.15.




Gambar 4.15 Perbandingan Waktu Inferensi Model pada 1.514 Data Uji Tahap 3

Temuan ini melengkapi analisis komparasi menjadi sebuah trade-off yang utuh. BiLSTM unggul dari sisi akurasi (WER lebih rendah), sedangkan BiGRU unggul dari sisi kecepatan inferensi. Perlu ditegaskan bahwa perbandingan waktu ini hanya sah antara BiGRU dan BiLSTM pada tahap yang sama, dan tidak dapat dibandingkan langsung dengan Gambar 4.5 pada Tahap 1 karena berbeda metode decoding maupun jumlah data uji.

4.9. Analisis Perbandingan Keseluruhan Tiga Tahap Eksperimen

Untuk melihat gambaran progres penelitian secara menyeluruh, Gambar 4.16 dan Tabel 4.13 merangkum performa BiGRU dan BiLSTM pada ketiga tahap eksperimen (baseline, regularisasi, dan perluasan dataset). Nilai yang digunakan pada perbandingan ini adalah hasil evaluasi pada data uji (test set). Nilai Tahap 1 dan Tahap 3 mengacu pada Tabel 4.5 dan Tabel 4.10, sedangkan nilai Tahap 2 diperoleh melalui evaluasi tambahan menggunakan skrip *evaluate_test.py* terhadap *checkpoint* terbaik masing-masing model Tahap 2 pada test set yang sama dengan Tahap 1, menghasilkan WER 49,48% dan CER 12,78% untuk BiGRU serta WER 43,38% dan CER 10,86% untuk BiLSTM.



Gambar 4.16 Ringkasan Perbandingan WER dan CER pada Tiga Tahap Eksperimen (Test Set)

Tabel 4.13 Ringkasan Progres Tiga Tahap Eksperimen (Metrik Test Set)

Tahap	Konfigurasi Utama	BiGRU WER / CER	BiLSTM WER / CER	BiGRU Akurasi Kata / Karakter	BiLSTM Akurasi Kata / Karakter
Tahap 1	Dataset 12.138, dropout 0,1	59,20% / 15,92%	54,82% / 14,63%	40,80% / 84,08%	45,18% / 85,37%
Tahap 2	+ Dropout 0,3, augmentasi, beam search	49,48% / 12,78%	43,38% / 10,86%	50,52% / 87,22%	56,62% / 89,14%
Tahap 3	+ Dataset diperluas jadi 30.256	28,13% / 7,01%	26,36% / 6,59%	71,87% / 92,99%	73,64% / 93,41%

Perlu dicatat bahwa test set yang digunakan pada Tahap 1 dan Tahap 2 berjumlah 1.215 data (Corpus 25.0), sedangkan Tahap 3 menggunakan 1.514 data (Corpus 24.0), dan metode decoding mengikuti konfigurasi masing-masing tahap (greedy pada Tahap 1, beam search pada Tahap 2 dan 3). Dengan demikian,

perbandingan antar tahap dimaknai sebagai gambaran progres konfigurasi secara keseluruhan, bukan perbandingan pada kondisi uji yang identik; adapun perbandingan BiGRU terhadap BiLSTM di dalam setiap tahap tetap sepenuhnya setara karena keduanya diuji pada data dan konfigurasi yang sama.

Secara keseluruhan, terlihat jelas bahwa peningkatan performa paling besar diperoleh dari perluasan dataset pada Tahap 3, dengan penurunan WER sebesar 21,35 poin persentase untuk BiGRU dan 17,02 poin persentase untuk BiLSTM dibandingkan Tahap 2. Hal ini mengonfirmasi dugaan yang telah diidentifikasi pada Sub-bab 4.13, bahwa ukuran dataset merupakan faktor paling dominan dalam menentukan performa akhir model ASR end-to-end, jauh melampaui kontribusi regularisasi, augmentasi, maupun strategi decoding secara individual. Meskipun demikian, kontribusi Tahap 2 tetap penting sebagai fondasi konfigurasi yang kemudian dipertahankan pada Tahap 3. Pada seluruh tahap eksperimen tanpa kecuali, BiLSTM secara konsisten mengungguli BiGRU, memperkuat kesimpulan bahwa mekanisme forget gate pada BiLSTM memberikan keunggulan dalam menangkap ketergantungan konteks jangka panjang pada sinyal ucapan Bahasa Indonesia.

Terkait besaran selisih antara kedua arsitektur, hasil ini perlu dinyatakan secara berimbang. Pada konfigurasi akhir (Tahap 3), selisih WER antara BiLSTM dan BiGRU sebesar 1,77 poin persentase (26,36% berbanding 28,13%), atau sekitar 6,3% secara relatif, sedangkan selisih CER sebesar 0,42 poin persentase. Besaran tersebut tergolong kecil apabila dibandingkan dengan pengaruh perluasan dataset, yang pada tahap yang sama menurunkan WER lebih dari 17 poin persentase. Yang memperkuat temuan ini karena itu bukan besar selisihnya, melainkan arahnya yang konsisten: BiLSTM unggul pada seluruh tahap eksperimen, pada metrik WER maupun CER, pada data validasi maupun data uji, serta pada pengujian demo rekaman mandiri (Sub-bab 4.13). Konsistensi tersebut selanjutnya diuji secara khusus melalui pengulangan pelatihan dengan tiga nilai *seed* berbeda, yang hasilnya diuraikan pada Sub-bab 4.11.

Selain pengujian antar-*seed*, signifikansi selisih tersebut turut diuji secara langsung pada data uji Tahap 3 menggunakan metode *paired bootstrap*. Karena kedua model dievaluasi pada 1.514 ucapan yang persis sama, kinerja keduanya dapat diperbandingkan secara berpasangan per ucapan. Prosedurnya dilakukan dengan mengambil ulang 1.514 ucapan secara acak dengan pengembalian sebanyak 10.000 kali, lalu menghitung selisih WER kedua model pada setiap pengambilan. Pengujian ini mengukur ketidakpastian yang berasal dari komposisi data uji, dan karena itu melengkapi pengujian antar-*seed* pada Sub-bab 4.11 yang mengukur ketidakpastian dari inisialisasi bobot.

Hasilnya menunjukkan selisih WER sebesar 1,77 poin persentase dengan selang kepercayaan 95% berada pada rentang 0,96 sampai 2,57 poin persentase. Selang tersebut tidak memuat nol, dan nilai p yang diperoleh lebih kecil daripada 0,0001. Uji tanda pada tingkat ucapan memberikan kesimpulan yang sejalan: BiLSTM menghasilkan transkripsi yang lebih baik pada 426 ucapan, BiGRU pada 301 ucapan, dan keduanya sama baik pada 787 ucapan, dengan nilai p yang juga lebih kecil daripada 0,0001. Dengan demikian, meskipun selisih 1,77 poin persentase tergolong kecil secara praktis, selisih tersebut tidak dapat dijelaskan sebagai kebetulan akibat komposisi data uji maupun akibat pengacakan bobot awal.

4.10. Analisis Kompleksitas Model

Selain akurasi, perbandingan antara kedua arsitektur perlu ditinjau dari sisi biaya komputasi, yaitu jumlah parameter, ukuran model tersimpan, waktu pelatihan, dan waktu inferensi. Jumlah parameter dihitung langsung dari konfigurasi arsitektur pada Sub-bab 3.4.4 dan diverifikasi terhadap model yang terbentuk di dalam program. Rangkuman perbandingannya disajikan pada Tabel 4.14.

Tabel 4.14 Perbandingan Kompleksitas Model BiGRU dan BiLSTM

Aspek	BiGRU	BiLSTM	Selisih
Parameter blok CNN	93.120	93.120	identik
Parameter lapisan rekuren	6.693.888	8.925.184	+2.231.296 (+33,3%)
Parameter lapisan keluaran	15.390	15.390	identik
Total parameter	6.802.398	9.033.694	+2.231.296 (+32,8%)
Ukuran bobot model (presisi 32-bit)	+/- 25,95 MB	+/- 34,46 MB	+8,51 MB
Waktu pelatihan Tahap 1 hingga early stopping	+/- 2 jam 16 menit (33 epoch)	+/- 1 jam 34 menit (28 epoch)	-42 menit
Waktu inferensi Tahap 3 (1.514 data uji)	9,35 detik	10,52 detik	+1,17 detik

Tabel 4.14 memperlihatkan bahwa hampir seluruh selisih kompleksitas berasal dari lapisan rekuren, yang menyumbang sekitar 98% dari total parameter pada kedua model. Blok CNN dan lapisan keluaran identik pada kedua skenario, sehingga perbandingan ini benar-benar mencerminkan perbedaan antara sel GRU dan sel LSTM. Selisih tersebut sesuai dengan teori: sel LSTM menghitung empat kelompok bobot, yaitu tiga gerbang ditambah kandidat *cell state*, sedangkan sel GRU hanya menghitung tiga kelompok, yaitu dua gerbang ditambah kandidat *hidden state*. Karena itu rasio parameter lapisan rekuren keduanya mendekati 4 berbanding 3.

Dari sisi ukuran penyimpanan, selisih 8,51 MB tergolong kecil untuk penggunaan pada komputer biasa, namun dapat menjadi pertimbangan pada penerapan di perangkat dengan memori terbatas. Perlu dicatat bahwa berkas *checkpoint* (best.pt) berukuran lebih besar daripada angka pada Tabel 4.14, karena selain bobot model berkas tersebut juga menyimpan status optimizer, kamus karakter, dan konfigurasi Mel-Spectrogram.

Temuan yang menarik terdapat pada waktu pelatihan. Meskipun memiliki parameter lebih banyak, total waktu pelatihan BiLSTM pada Tahap 1 justru lebih singkat, yaitu sekitar 1 jam 34 menit dibandingkan 2 jam 16 menit pada BiGRU. Hal ini bukan berarti BiLSTM lebih ringan per *epoch*, melainkan karena BiLSTM mencapai WER validasi terbaiknya lebih cepat sehingga mekanisme *early stopping* menghentikan pelatihannya pada *epoch* ke-28, sementara BiGRU baru berhenti

pada *epoch* ke-33. Dengan kata lain, besaran yang dibandingkan pada baris tersebut adalah total waktu sampai konvergensi, bukan waktu komputasi per *epoch*.

Sebaliknya, pada waktu inferensi pola teoretis kembali terlihat. BiGRU memerlukan 9,35 detik sedangkan BiLSTM 10,52 detik untuk memproses 1.514 data uji, sehingga BiGRU sekitar 11% lebih cepat. Pengukuran inferensi tidak dipengaruhi mekanisme *early stopping* sehingga langsung mencerminkan beban komputasi per langkah waktu.

Secara keseluruhan, analisis kompleksitas ini menegaskan bentuk *trade-off* pada penelitian ini: BiLSTM menawarkan akurasi yang lebih baik dengan biaya sekitar 33% parameter tambahan dan waktu inferensi sekitar 11% lebih lambat, sedangkan BiGRU menawarkan model yang lebih ringkas dan cepat dengan selisih WER 1,77 poin persentase pada konfigurasi akhir.

4.11. Validasi Keberulangan Hasil dengan Beberapa Nilai Seed

Nilai *seed* menentukan bobot awal jaringan syaraf tiruan sebelum pelatihan dimulai, sehingga dua kali pelatihan dengan konfigurasi yang persis sama pun dapat menghasilkan kinerja akhir yang sedikit berbeda. Untuk mengetahui apakah selisih kinerja antara BiGRU dan BiLSTM benar-benar bersumber dari perbedaan arsitektur dan bukan sekadar akibat pengacakan bobot awal, setiap arsitektur dilatih ulang sebanyak tiga kali menggunakan tiga nilai *seed* yang berbeda, yaitu 7, 42, dan 2025.

Pengujian ini dilakukan pada konfigurasi Tahap 1 dengan pertimbangan waktu komputasi, karena Tahap 3 memiliki jumlah data latih sekitar 2,8 kali lebih besar dan menggunakan *beam search* pada setiap evaluasi *epoch*. Pilihan tersebut sekaligus menguntungkan dari sisi kehati-hatian: Tahap 1 merupakan kondisi yang paling tidak stabil karena data latihnya paling sedikit dan belum menerapkan regularisasi tambahan, sehingga variasi antar-*seed* yang terukur di sini dapat dipandang sebagai batas atas. Seluruh parameter selain nilai *seed* dibuat identik dengan Tahap 1 sebagaimana dirinci pada Sub-bab 3.4.4. Hasil keenam pelatihan disajikan pada Tabel 4.15.

Tabel 4.15 Hasil WER Validasi pada Tiga Nilai Seed (Konfigurasi Tahap 1)

Arsitektur	Seed 7	Seed 42	Seed 2025	Rata-rata +/- Simpangan
BiGRU	61,13	59,99	59,80	60,31 +/- 0,72
BiLSTM	55,64	56,32	57,07	56,34 +/- 0,72

Tabel 4.15 memperlihatkan bahwa variasi akibat inisialisasi bobot acak memang ada, namun besarnya terbatas. Simpangan baku WER kedua arsitektur sama, yaitu 0,72 poin persentase, dengan rentang 59,80% sampai 61,13% pada BiGRU dan 55,64% sampai 57,07% pada BiLSTM. Pada metrik CER, rata-rata BiGRU sebesar 16,81% dengan simpangan baku 0,32, sedangkan BiLSTM sebesar 15,67% dengan simpangan baku 0,19.

Temuan yang paling menentukan adalah bahwa kedua rentang tersebut tidak saling tumpang tindih. Nilai WER terburuk yang dicapai BiLSTM, yaitu 57,07%, masih lebih baik daripada nilai WER terbaik yang dicapai BiGRU, yaitu 59,80%, dengan jarak 2,73 poin persentase. Dengan kata lain, ketiga pelatihan BiLSTM seluruhnya mengungguli ketiga pelatihan BiGRU tanpa satu pun perkecualian. Selisih rata-rata sebesar 3,96 poin persentase juga setara dengan sekitar 5,5 kali simpangan baku antar-*seed*. Uji t dua sampel terhadap keenam hasil tersebut menghasilkan nilai t sebesar 6,77 dengan derajat bebas 4 dan nilai p sebesar 0,0025 untuk WER, serta nilai p sebesar 0,0059 untuk CER. Keduanya berada di bawah taraf 0,05, sehingga keunggulan BiLSTM dapat dinyatakan signifikan secara statistik dan bukan merupakan kebetulan akibat pengacakan bobot awal.

Satu catatan metodologis perlu ditambahkan. Pelatihan dengan *seed* 7 pada BiGRU berhenti pada *epoch* ke-20 dengan WER terbaik 61,13%, sedangkan dua *seed* lainnya berjalan hingga *epoch* ke-30 dan ke-33 serta mendarat pada kisaran 59,8% sampai 60,0%. Perbedaan tersebut menunjukkan bahwa sebagian variasi yang terukur tidak murni berasal dari inisialisasi bobot, melainkan dari interaksi antara mekanisme *early stopping* dan fluktuasi WER validasi: ketika WER mendarat sesaat selama lima *epoch* berturut-turut, pelatihan dihentikan meskipun model masih berpotensi membaik. Dengan demikian, variasi yang benar-benar disebabkan oleh pengacakan bobot awal kemungkinan lebih kecil daripada 0,72 poin persentase yang tercatat.

Perlu dinyatakan pula batas keberlakuan hasil ini. Pengukuran dilakukan pada konfigurasi Tahap 1, sedangkan konfigurasi akhir penelitian berada pada Tahap 3 dengan selisih WER antar-arsitektur sebesar 1,77 poin persentase. Besaran variasi antar-*seed* pada Tahap 3 belum diukur secara langsung dan belum tentu identik dengan Tahap 1, meskipun jumlah data yang jauh lebih besar serta penerapan *dropout* 0,3 pada Tahap 3 secara umum cenderung menstabilkan proses pelatihan. Pengulangan pengujian keberulangan pada konfigurasi Tahap 3 karena itu tetap dicantumkan sebagai saran penelitian lanjutan pada Bab V.

4.12. Uji Ablasi Strategi Decoding

Sebagaimana dinyatakan pada Sub-bab 4.7, Tahap 2 menerapkan tiga perubahan sekaligus terhadap konfigurasi *baseline*, yaitu peningkatan *dropout* dari 0,1 menjadi 0,3, pengaktifan augmentasi audio, dan penggantian strategi *decoding* dari *greedy* menjadi *beam search*. Di antara ketiganya, pengaruh strategi *decoding* dapat diisolasi tanpa melatih ulang model, sebab *decoding* merupakan proses yang berlangsung setelah pelatihan selesai. Model yang sama persis dapat dievaluasi dua kali dengan strategi *decoding* yang berbeda.

Uji ablasi ini dilakukan dengan mengevaluasi ulang *checkpoint* Tahap 1, yaitu model yang dilatih tanpa augmentasi dan dengan *dropout* 0,1, pada data uji yang sama sebanyak 1.215 ucapan. Evaluasi dijalankan dua kali untuk setiap arsitektur, yakni menggunakan *greedy decoding* dan menggunakan *beam search* dengan lebar beam 10. Karena bobot model tidak berubah sedikit pun di antara kedua evaluasi tersebut, selisih yang muncul murni berasal dari strategi *decoding*. Hasilnya disajikan pada Tabel 4.16.

Tabel 4.16 Hasil Uji Ablasi Strategi Decoding pada Checkpoint Tahap 1 (Data Uji, 1.215 Ucapan)

Arsitektur	WER Greedy (%)	WER Beam (%)	Selisih WER (pp)	CER Greedy / Beam (%)
BiGRU	59,20	58,73	-0,47	15,92 / 15,75
BiLSTM	54,82	54,41	-0,41	14,64 / 14,46

Nilai WER pada kolom *greedy* di Tabel 4.16 sama persis dengan hasil evaluasi Tahap 1 yang telah dilaporkan pada Tabel 4.5, yaitu 59,20% untuk BiGRU dan 54,82% untuk BiLSTM. Kesesuaian ini menegaskan bahwa prosedur evaluasi

ulang yang digunakan pada uji ablasi identik dengan prosedur evaluasi utama penelitian, sehingga selisih yang terbaca dapat dipercaya.

Hasilnya menunjukkan bahwa penggantian strategi *decoding* dari *greedy* menjadi *beam search* hanya menurunkan WER sebesar 0,47 poin persentase pada BiGRU dan 0,41 poin persentase pada BiLSTM, dengan penurunan CER masing-masing sebesar 0,17 dan 0,18 poin persentase. Besaran tersebut jauh lebih kecil daripada perkiraan yang lazim, dan implikasinya penting untuk menafsirkan hasil Tahap 2.

Total penurunan WER dari Tahap 1 ke Tahap 2 pada data uji adalah 9,72 poin persentase untuk BiGRU (dari 59,20% menjadi 49,48%) dan 11,44 poin persentase untuk BiLSTM (dari 54,82% menjadi 43,38%). Apabila sumbangan *beam search* sebesar 0,47 dan 0,41 poin persentase dikurangkan, maka strategi *decoding* hanya menyumbang sekitar 4,8% dari keseluruhan perbaikan pada BiGRU dan sekitar 3,6% pada BiLSTM. Dengan kata lain, lebih dari 95% perbaikan yang dicapai pada Tahap 2 berasal dari peningkatan *dropout* dan augmentasi audio, bukan dari perubahan cara *decoding*.

Temuan ini sekaligus menjelaskan mengapa penerapan ketiga perubahan secara bersamaan pada Tahap 2 tidak menimbulkan ambiguitas yang berarti terhadap kesimpulan penelitian: komponen yang paling mudah dicurigai memberi keuntungan semu, yaitu *beam search*, ternyata justru yang paling kecil pengaruhnya. Meskipun demikian, pengaruh *dropout* dan augmentasi audio masih belum dapat dipisahkan satu sama lain karena keduanya bekerja pada saat pelatihan berlangsung, sehingga pemisahannya mengharuskan model dilatih ulang. Hal tersebut dicantumkan sebagai keterbatasan pada Sub-bab 4.13 dan sebagai saran pada Bab V.

4.13. Pembahasan Umum dan Keterbatasan Sistem

Perlu ditegaskan bahwa fokus penelitian ini adalah membandingkan kinerja lapisan BiGRU dan BiLSTM pada arsitektur CRNN, bukan membangun sistem ASR berskala produksi. Meskipun target performa (WER di bawah 30%, CER di bawah 10%) berhasil dicapai pada Tahap 3 (Sub-bab 4.8), beberapa keterbatasan berikut tetap perlu diungkapkan secara jujur karena turut memengaruhi validitas dan generalisasi hasil penelitian:

1. Ukuran dan variasi dataset. Keterbatasan ini telah ditindaklanjuti pada Tahap 3 dengan memperluas dataset dari 12.138 menjadi 30.256 data, yang terbukti menjadi faktor paling berpengaruh dalam menurunkan WER dan CER (Sub-bab 4.9). Meskipun demikian, dataset ini tetap bersumber dari satu korpus yang sama (Mozilla Common Voice), sehingga variasi dialek, dan gaya bicara yang tercakup masih terbatas pada karakteristik kontributor korpus tersebut. Penggunaan dataset gabungan dari beberapa korpus atau penambahan data rekaman mandiri berpotensi meningkatkan generalisasi model lebih jauh.

2. Strategi decoding tanpa language model eksternal. Sejak Tahap 2, evaluasi model pada data validasi dan data uji telah menggunakan beam search decoding (lebar beam 10) melalui modul `ctc_decode.py`, menggantikan greedy decoding pada Tahap 1. Namun demikian, skrip inferensi real-time (`infer.py`) untuk pengujian pada berkas audio tunggal tetap menggunakan greedy decoding demi kecepatan proses. Selain itu, beam search yang diimplementasikan pada penelitian ini belum melibatkan language model (LM) eksternal Bahasa Indonesia untuk melakukan rescoring, sehingga potensi perbaikan pada tingkat kata (bukan hanya tingkat karakter) belum sepenuhnya dimanfaatkan.

Ilustrasi konkret keterbatasan tersebut dapat dilihat pada contoh prediksi yang disajikan pada Sub-bab 4.8 serta pada hasil demo inferensi yang diuraikan pada butir 4 di bawah, di mana sebagian kesalahan berupa penggabungan atau pemisahan kata yang seharusnya dapat dikoreksi apabila tersedia *language model* eksternal.

3. Variasi augmentasi data yang masih terbatas. Berbeda dengan Tahap 1, augmentasi data (random gain, derau Gaussian, serta SpecAugment) telah diaktifkan sejak Tahap 2 dan terbukti berkontribusi terhadap penurunan WER dan CER. Meskipun demikian, augmentasi yang diterapkan bersifat sintesis dan belum merepresentasikan variasi derau lingkungan nyata (misalnya suara latar belakang, gema ruangan, atau karakteristik mikrofon yang berbeda), sehingga model tetap menunjukkan

kesulitan ketika diuji pada rekaman di luar korpus Common Voice, sebagaimana diilustrasikan berikut ini.

4. Generalisasi terhadap rekaman di luar domain dataset. Untuk menguji kemampuan generalisasi model secara terkendali, dilakukan demo inferensi terhadap sembilan rekaman suara pribadi penulis yang dibagi menjadi tiga kelompok berdasarkan asal kalimatnya: tiga kalimat dari data latih, tiga kalimat dari data uji, dan tiga kalimat karangan sendiri yang tidak berasal dari korpus. Seluruh rekaman diproses menggunakan *beam search decoding* dengan lebar beam 10, konsisten dengan konfigurasi evaluasi Tahap 3. Rancangan ini memisahkan dua faktor yang sebelumnya bercampur: karena seluruh rekaman berasal dari penutur, mikrofon, dan lingkungan yang sama, perbedaan antar kelompok mencerminkan pengaruh asal teks, bukan perbedaan kondisi akustik. Hasil selengkapnya disajikan pada Tabel 4.17 sampai Tabel 4.19 serta Gambar 4.17.

Tabel 4.17 Hasil Demo Inferensi Model BiLSTM pada Sembilan Rekaman Suara Pribadi (Beam Search Decoding, Lebar 10)

No	Kelompok	Teks Acuan	Teks Dikenali	WER	CER
1	Data Latih	saat aku sedang menunggu bus aku melihat kecelakaan lalu lintas	(identik dengan teks acuan)	0,00%	0,00%
2	Data Latih	mengapa kamu tidak menghubungiku untuk meminta bantuan	(identik dengan teks acuan)	0,00%	0,00%
3	Data Latih	anda selalu makan siang di mana	(identik dengan teks acuan)	0,00%	0,00%
4	Data Uji	tom terlalu tua untuk melakukan hal semacam ini	(identik dengan teks acuan)	0,00%	0,00%
5	Data Uji	hubungan diplomatik kedua negara itu sedang panas	hubungan dipromatik kedua negara itu sedang panas	14,29%	2,04%
6	Data Uji	adalah tidak mungkin untuk kembali ke masa lalu	(identik dengan teks acuan)	0,00%	0,00%
7	Karangan Sendiri	pagi tadi saya berjalan kaki menuju kampus bersama teman	(identik dengan teks acuan)	0,00%	0,00%
8	Karangan Sendiri	buku itu diletakkan di atas meja dekat jendela kamar	buku itu dilatakan di atas meja dekat jendela kamar	11,11%	3,85%
9	Karangan Sendiri	banyak orang menunggu kereta di stasiun sejak pagi buta	(identik dengan teks acuan)	0,00%	0,00%

Tabel 4.18 Hasil Demo Inferensi Model BiGRU pada Sembilan Rekaman Suara Pribadi (Beam Search Decoding, Lebar 10)

No	Kelompok	Teks Acuan	Teks Dikenali	WER	CER
1	Data Latih	saat aku sedang menunggu bus aku melihat kecelakaan lalu lintas	(identik dengan teks acuan)	0,00%	0,00%
2	Data Latih	mengapa kamu tidak menghubungiku untuk meminta bantuan	(identik dengan teks acuan)	0,00%	0,00%
3	Data Latih	anda selalu makan siang di mana	(identik dengan teks acuan)	0,00%	0,00%
4	Data Uji	tom terlalu tua untuk melakukan hal semacam ini	tom terlali tua untuk melakukan hal semacam ini	12,50%	2,13%
5	Data Uji	hubungan diplomatik kedua negara itu sedang panas	hubungan di promati kedua negara itu sedang panas	28,57%	6,12%
6	Data Uji	adalah tidak mungkin untuk kembali ke masa lalu	(identik dengan teks acuan)	0,00%	0,00%
7	Karangan Sendiri	pagi tadi saya berjalan kaki menuju kampus bersama teman	(identik dengan teks acuan)	0,00%	0,00%
8	Karangan Sendiri	buku itu diletakkan di atas meja dekat jendela kamar	buku itu dilatakan di atas meja dekat jendela kamar	11,11%	3,85%
9	Karangan Sendiri	banyak orang menunggu kereta di stasiun sejak pagi buta	banyak orang menunggu kereta di stasiuun sejak pagi buta	11,11%	1,82%

Tabel 4.19 Rekapitulasi WER dan CER per Kelompok Rekaman pada Demo Inferensi

Kelompok	BiLSTM WER	BiLSTM CER	BiGRU WER	BiGRU CER
Data Latih	0,00%	0,00%	0,00%	0,00%
Data Uji	4,35%	0,70%	13,04%	2,80%
Karangan Sendiri	3,70%	1,23%	7,41%	1,84%
Keseluruhan (73 kata)	2,74%	0,66%	6,85%	1,54%

```

[1] Data Latih      acuan : saat aku sedang menunggu bus aku melihat kecelakaan lalu lintas
    BiLSTM hasil : saat aku sedang menunggu bus aku melihat kecelakaan lalu lintas
                   WER  0.00% CER  0.00% (0.35 detik)
    BiGRU  hasil : saat aku sedang menunggu bus aku melihat kecelakaan lalu lintas
                   WER  0.00% CER  0.00% (0.17 detik)

[2] Data Latih      acuan : mengapa kamu tidak menghubungiku untuk meminta bantuan
    BiLSTM hasil : mengapa kamu tidak menghubungiku untuk meminta bantuan
                   WER  0.00% CER  0.00% (0.14 detik)
    BiGRU  hasil : mengapa kamu tidak menghubungiku untuk meminta bantuan
                   WER  0.00% CER  0.00% (0.15 detik)

[3] Data Latih      acuan : anda selalu makan siang di mana
    BiLSTM hasil : anda selalu makan siang di mana
                   WER  0.00% CER  0.00% (0.11 detik)
    BiGRU  hasil : anda selalu makan siang di mana
                   WER  0.00% CER  0.00% (0.10 detik)

[4] Data Uji        acuan : tom terlalu tua untuk melakukan hal semacam ini
    BiLSTM hasil : tom terlalu tua untuk melakukan hal semacam ini
                   WER  0.00% CER  0.00% (0.13 detik)
    BiGRU  hasil : tom terlali tua untuk melakukan hal semacam ini
                   WER  12.50% CER  2.13% (0.11 detik)

[5] Data Uji        acuan : hubungan diplomatik kedua negara itu sedang panas
    BiLSTM hasil : hubungan dipromatik kedua negara itu sedang panas
                   WER  14.29% CER  2.04% (0.17 detik)
    BiGRU  hasil : hubungan di promati kedua negara itu sedang panas
                   WER  28.57% CER  6.12% (0.16 detik)

[6] Data Uji        acuan : adalah tidak mungkin untuk kembali ke masa lalu
    BiLSTM hasil : adalah tidak mungkin untuk kembali ke masa lalu
                   WER  0.00% CER  0.00% (0.13 detik)
    BiGRU  hasil : adalah tidak mungkin untuk kembali ke masa lalu
                   WER  0.00% CER  0.00% (0.11 detik)

[7] Karangan Sendiri acuan : pagi tadi saya berjalan kaki menuju kampus bersama teman
    BiLSTM hasil : pagi tadi saya berjalan kaki menuju kampus bersama teman
                   WER  0.00% CER  0.00% (0.16 detik)
    BiGRU  hasil : pagi tadi saya berjalan kaki menuju kampus bersama teman
                   WER  0.00% CER  0.00% (0.17 detik)

[8] Karangan Sendiri acuan : buku itu diletakkan di atas meja dekat jendela kamar
    BiLSTM hasil : buku itu dilatakan di atas meja dekat jendela kamar
                   WER  11.11% CER  3.85% (0.16 detik)
    BiGRU  hasil : buku itu dilatakan di atas meja dekat jendela kamar
                   WER  11.11% CER  3.85% (0.16 detik)

[9] Karangan Sendiri acuan : banyak orang menunggu kereta di stasiun sejak pagi buta
    BiLSTM hasil : banyak orang menunggu kereta di stasiun sejak pagi buta
                   WER  0.00% CER  0.00% (0.17 detik)
    BiGRU  hasil : banyak orang menunggu kereta di stasiuun sejak pagi buta
                   WER  11.11% CER  1.82% (0.17 detik)

```

Gambar 4.17 Keluaran Program Demo Inferensi pada Sembilan Rekaman Suara Pribadi: (a) kalimat dari data latih, (b) kalimat dari data uji, (c) kalimat karangan sendiri

Hasil pada Tabel 4.17 dan Tabel 4.18 menunjukkan bahwa BiLSTM mentranskripsikan tujuh dari sembilan rekaman secara sempurna dengan WER

keseluruhan 2,74% dan CER 0,66%, sedangkan BiGRU mentranskripsikan lima rekaman secara sempurna dengan WER 6,85% dan CER 1,54%. Keunggulan BiLSTM atas BiGRU yang teramati pada seluruh tahap eksperimen kembali terkonfirmasi pada pengujian ini.

Temuan terpenting terlihat pada perbandingan antar kelompok pada Tabel 4.19. Kelompok kalimat karangan sendiri — yang teks maupun susunan katanya tidak pernah muncul dalam korpus — menghasilkan WER 3,70% pada BiLSTM, hampir setara dengan kelompok data latih (0,00%) dan bahkan lebih rendah daripada kelompok data uji (4,35%). Hal ini menunjukkan bahwa model tidak sekadar menghafal kalimat pada data latih, melainkan mempelajari pemetaan dari pola akustik ke urutan karakter, sehingga mampu mentranskripsikan kalimat yang sepenuhnya baru. Mengingat setiap kelompok hanya memuat tiga kalimat, perbandingan ini bersifat kualitatif dan tidak dimaksudkan sebagai pengujian statistik.

Kesalahan yang muncul bersifat fonetis dan terbatas pada satu kata per kalimat, yaitu *diplomantik* menjadi *dipromatik*, *diletakkan* menjadi *dilatakan*, *terlalu* menjadi *terlali*, dan *stasiun* menjadi *stasiuun*. Pola kesalahan ini berupa kekeliruan membedakan fonem yang berdekatan (/l/ dengan /r/, /e/ dengan /a/) serta penggandaan vokal, bukan kegagalan mengenali struktur kata secara keseluruhan, dan konsisten dengan karakteristik model tingkat karakter tanpa *language model* eksternal.

Nilai WER pada pengujian ini jauh lebih rendah daripada hasil evaluasi pada data uji Tahap 3 (26,36% untuk BiLSTM). Perbedaan tersebut wajar dan perlu dimaknai secara hati-hati: rekaman demo dibuat dalam kondisi terkendali dengan satu penutur, artikulasi jelas, dan lingkungan minim derau, sedangkan data uji memuat 1.514 rekaman dari beragam penutur dengan variasi aksen, kualitas mikrofon, dan tingkat derau yang jauh lebih luas. Dengan demikian hasil demo ini menggambarkan batas atas kinerja model pada kondisi rekaman ideal, sementara nilai pada Tabel 4.10 tetap menjadi estimasi kinerja yang representatif untuk penggunaan umum.

5. Uji ablasi yang baru sebagian. Pada Tahap 2, tiga perubahan diterapkan sekaligus, yaitu peningkatan *dropout* dari 0,1 menjadi 0,3, pengaktifan augmentasi audio, dan penggantian strategi *decoding* menjadi *beam search*. Pengaruh strategi *decoding* telah berhasil diisolasi melalui uji ablasi pada Sub-bab 4.12 dan ternyata hanya menyumbang sekitar 4% dari keseluruhan perbaikan. Adapun pengaruh *dropout* dan augmentasi audio masih belum dapat dipisahkan satu sama lain, sebab keduanya bekerja pada saat pelatihan berlangsung sehingga pemisahannya mengharuskan model dilatih ulang dari awal. Uji ablasi menyeluruh terhadap kedua komponen tersebut disarankan untuk penelitian selanjutnya.

6. Pengujian keberulangan yang terbatas pada konfigurasi Tahap 1. Pengulangan pelatihan dengan tiga nilai *seed* berbeda telah dilakukan dan hasilnya diuraikan pada Sub-bab 4.11, namun pengujian tersebut hanya dijalankan pada konfigurasi Tahap 1 karena keterbatasan waktu komputasi. Besarnya variasi antar-*seed* pada konfigurasi Tahap 3, yang menjadi konfigurasi akhir penelitian, belum diukur secara langsung. Meskipun demikian, Tahap 1 merupakan kondisi dengan data latih paling sedikit dan tanpa regularisasi tambahan, sehingga simpangan baku sebesar 0,72 poin persentase yang terukur di sana dapat dipandang sebagai batas atas.

Keenam keterbatasan tersebut membuka ruang perbaikan yang akan dibahas lebih lanjut sebagai saran pengembangan pada Bab V.

BAB V

PENUTUP

5.1. Kesimpulan

Berdasarkan hasil perancangan, implementasi, dan pengujian sistem pengenalan ucapan (*Automatic Speech Recognition/ASR*) Bahasa Indonesia berbasis arsitektur CRNN-CTC yang membandingkan lapisan rekuren BiGRU dan BiLSTM, diperoleh kesimpulan sebagai berikut, yang disusun untuk menjawab ketiga rumusan masalah penelitian:

1. Identifikasi Data dan Fitur. Dataset audio Mozilla Common Voice Bahasa Indonesia (cv-id) berhasil dimuat, divalidasi, dan dibagi menjadi tiga subset independen. Pada konfigurasi akhir penelitian, keseluruhan data tervalidasi sebanyak 30.256 sampel dibagi dengan rasio 90:5:5 menjadi 27.230 data latih, 1.512 data validasi, dan 1.514 data uji. Setiap sinyal audio (mono, 16.000 Hz) berhasil diekstraksi menjadi representasi Mel-Spectrogram 2D ($n_{\text{mels}} = 80$) yang terbukti dapat digunakan sebagai masukan bagi blok CNN, dengan ukuran kamus karakter sebanyak 30 token.

2. Desain dan Implementasi. Arsitektur CRNN dengan lapisan rekuren BiGRU dan BiLSTM berhasil dirancang dan diimplementasikan menggunakan pustaka PyTorch, dengan penyelarasan urutan audio ke teks menggunakan fungsi kerugian *Connectionist Temporal Classification* (CTC) Loss. Kedua skenario dibangun dari basis kode yang identik dan hanya dibedakan oleh parameter *rnn_type*, sehingga perbedaan performa yang dihasilkan murni disebabkan oleh perbedaan mekanisme gerbang pada lapisan rekuren.

3. Evaluasi Perbandingan Kinerja. Pada konfigurasi akhir penelitian, BiLSTM mengungguli BiGRU dari sisi akurasi pengenalan. Pada data uji sebanyak 1.514 sampel dengan beam search decoding lebar 10, BiLSTM mencapai WER 26,36% dan CER 6,59% — setara dengan akurasi kata 73,64% dan akurasi karakter 93,41% — sedangkan BiGRU mencapai WER 28,13% dan CER 7,01%, setara dengan akurasi kata 71,87% dan akurasi

karakter 92,99%. Sebaliknya, dari sisi kecepatan BiGRU lebih unggul dengan waktu inferensi 9,35 detik dibandingkan BiLSTM yang membutuhkan 10,52 detik untuk keseluruhan data uji.

4. Pencapaian Target Performa. Target performa yang ditetapkan pada awal penelitian, yaitu WER di bawah 30% dan CER di bawah 10%, berhasil dipenuhi oleh kedua model. Di antara faktor-faktor yang diuji, perluasan ukuran dataset pelatihan menjadi 30.256 data teridentifikasi sebagai faktor yang memberikan kontribusi perbaikan paling besar, melampaui pengaruh regularisasi maupun strategi decoding.

Secara keseluruhan, dapat disimpulkan bahwa untuk kasus pengenalan ucapan Bahasa Indonesia pada korpus Mozilla Common Voice dengan arsitektur CRNN-CTC, lapisan Bidirectional Long Short-Term Memory (BiLSTM) memberikan trade-off yang lebih menguntungkan dibandingkan Bidirectional Gated Recurrent Unit (BiGRU): BiLSTM lebih akurat, sementara BiGRU lebih cepat, sehingga BiLSTM direkomendasikan apabila akurasi menjadi prioritas utama. Selain itu, penelitian ini menunjukkan secara empiris bahwa di antara faktor-faktor yang diuji (regularisasi, augmentasi data, strategi decoding, dan ukuran dataset), perluasan ukuran dataset memberikan pengaruh paling signifikan terhadap penurunan tingkat kesalahan model.

Perlu ditegaskan bahwa temuan mengenai dominasi faktor dataset tidak menggugurkan sifat penelitian ini sebagai studi komparasi BiGRU dan BiLSTM. Kedua temuan tersebut menjawab pertanyaan yang berbeda dan diperoleh dari perbandingan yang berbeda pula. Perbandingan antar-arsitektur dilakukan di dalam setiap tahap, yaitu antara BiGRU dan BiLSTM yang dilatih pada data, konfigurasi, dan metode *decoding* yang persis sama; perbandingan inilah yang menjadi inti penelitian, dan hasilnya konsisten pada ketiga tahap. Adapun perbandingan antar-tahap dilakukan pada arsitektur yang sama dengan jumlah data yang berbeda, dan hasilnya merupakan temuan tambahan mengenai faktor apa yang paling menentukan kinerja. Dengan kata lain, ukuran dataset berperan sebagai variabel yang divariasikan secara sengaja untuk menguji apakah keunggulan salah satu arsitektur tetap bertahan pada tiga kondisi data yang berbeda, dan ternyata bertahan. Justru karena diuji pada tiga skala data, kesimpulan komparasi arsitektur pada

penelitian ini menjadi lebih kuat dibandingkan apabila hanya diuji pada satu kondisi saja.

5.2. Saran

Mengacu pada keterbatasan yang telah diuraikan pada Sub-bab 4.13, beberapa saran yang dapat dijadikan acuan untuk pengembangan dan penelitian selanjutnya adalah sebagai berikut:

1. Perluasan dataset lebih lanjut. Penelitian ini telah membuktikan bahwa perluasan dataset dari 12.138 menjadi 30.256 data (memanfaatkan *validated.tsv* pada korpus yang sama) memberikan penurunan WER dan CER yang signifikan. Penelitian selanjutnya disarankan melanjutkan arah ini dengan menggabungkan beberapa korpus Bahasa Indonesia yang berbeda atau menambahkan data rekaman mandiri, guna meningkatkan variasi dialek dan gaya bicara yang tercakup, mengingat dataset pada penelitian ini masih bersumber dari satu korpus yang sama.
2. Augmentasi data dengan variasi derau yang lebih realistis. Augmentasi data (random gain, derau Gaussian, dan SpecAugment) telah diaktifkan sejak Tahap 2 dan terbukti membantu menurunkan WER dan CER. Namun demikian, sebagaimana ditunjukkan pada Tabel 4.17 dan Tabel 4.18, model masih kesulitan mengenali rekaman di luar korpus Common Voice. Penelitian selanjutnya disarankan menambahkan augmentasi dengan derau lingkungan nyata (background noise, reverberasi ruangan, variasi karakteristik mikrofon) agar model lebih robust terhadap kondisi rekaman dunia nyata.
3. Eksplorasi arsitektur lanjutan. Penelitian berikutnya dapat mengeksplorasi arsitektur ASR modern lainnya seperti *Transformer* atau *Conformer*, serta membandingkannya dengan arsitektur CRNN-CTC pada penelitian ini untuk memperoleh gambaran yang lebih menyeluruh mengenai performa pengenalan ucapan Bahasa Indonesia.
4. Uji ablasi terhadap dropout dan augmentasi secara terpisah. Pengaruh strategi *decoding* telah diuji secara terpisah pada penelitian ini dan hasilnya dilaporkan pada Sub-bab 4.12. Penelitian selanjutnya disarankan melanjutkan dengan menguji

pengaruh *dropout* dan augmentasi audio secara sendiri-sendiri, yaitu dengan melatih model menggunakan satu perubahan pada satu waktu terhadap konfigurasi *baseline*, agar sumbangan masing-masing komponen terhadap penurunan WER dapat diukur secara langsung.

5. Pengujian keberulangan pada konfigurasi Tahap 3. Pengulangan pelatihan dengan tiga nilai *seed* telah dilakukan pada konfigurasi Tahap 1 dan menunjukkan keunggulan BiLSTM yang konsisten. Penelitian selanjutnya disarankan mengulang pengujian serupa pada konfigurasi Tahap 3 agar besarnya variasi akibat inisialisasi bobot acak pada konfigurasi akhir dapat diketahui secara langsung, serta memperbanyak jumlah *seed* agar estimasi simpangan bakunya lebih stabil.

Daftar Pustaka

- Aini, Y. K., Santoso, T. B., & Dutono, T. (2021). Pemodelan CNN untuk deteksi emosi berbasis speech Bahasa Indonesia. *Jurnal Komputer Terapan*, 7(1), 143-152.
- Ardila, R., Branson, M., Davis, K., Kohler, M., Meyer, J., Henretty, M., ... & Weber, G. (2020, May). Common voice: A massively-multilingual speech corpus. In *Proceedings of the twelfth language resources and evaluation conference* (pp. 4218-4222).
- Arisaputra, P., & Zahra, A. (2022). Indonesian automatic speech recognition with XLSR-53. *Ingenierie des Systemes d'Information*, 27(6), 973-982. <https://doi.org/10.18280/isi.270614>
- Cakir, E., Parascandolo, G., Heittola, T., Huttunen, H., & Virtanen, T. (2017). Convolutional recurrent neural networks for polyphonic sound event detection. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 25(6), 1291-1303.
- Chung, J., Gulcehre, C., Cho, K., & Bengio, Y. (2014). Empirical evaluation of gated recurrent neural networks on sequence modeling. *arXiv preprint arXiv:1412.3555*.
- Dwijayanti, S., Akbar, A. R., & Suprpto, B. Y. (2024). Designing human-robot communication in the Indonesian language using the deep bidirectional long short-term memory algorithm. *Jurnal Elektronika dan Telekomunikasi*, 24(1), 1-11. <https://doi.org/10.55981/jet.595>
- Endah, S. N., Rismiyati, Sasongko, P. S., & Naiborhu, A. P. F. (2025). Indonesian continuous speech recognition optimization with convolution bidirectional long short-term memory architecture. *TELKOMNIKA Telecommunication Computing Electronics and Control*, 23(3), 807-815. <https://doi.org/10.12928/TELKOMNIKA.v23i3.24994>
- Firmansyah, B. A., & Bachtiar, F. A. (2021). *Automatic Speech Recognition Bahasa Indonesia menggunakan Unidirectional Gated Recurrent Unit. J-PTIIK Universitas Brawijaya* 5(1).

- Graves, A., Fernández, S., Gomez, F., & Schmidhuber, J. (2006, June). Connectionist temporal classification: labelling unsegmented sequence data with recurrent neural networks. In *Proceedings of the 23rd international conference on Machine learning* (pp. 369-376).
- Hamayel, M. J., & Owda, A. Y. (2021). A novel cryptocurrency price prediction model using GRU, LSTM and bi-LSTM machine learning algorithms. *AI*, 2(4), 477–496. <https://doi.org/10.3390/ai2040030>
- Hannun, A., Case, C., Casper, J., Catanzaro, B., Diamos, G., Elsen, E., ... & Ng, A. Y. (2014). Deep speech: Scaling up end-to-end speech recognition. *arXiv preprint arXiv:1412.5567*.
- Kizito, R., Scruggs, P., Li, X., Devinney, M., Jansen, J., & Kress, R. (2021). Long short-term memory networks for facility infrastructure failure and remaining useful life prediction. *IEEE Access*, 9, 67585-67594. <https://doi.org/10.1109/ACCESS.2021.3077192>
- Loshchilov, I., & Hutter, F. (2019). Decoupled weight decay regularization. *International Conference on Learning Representations (ICLR 2019)*. <https://doi.org/10.48550/arXiv.1711.05101>
- Mienye, I. D., Swart, T. G., & Obaido, G. (2024). Recurrent Neural Networks: A Comprehensive Review of Architectures, Variants, and Applications. *Information*, 15(9), 517. <https://doi.org/10.3390/info15090517>
- Nugraha, A. S., & Hidayat, T. (2022). Analisis perbandingan ekstraksi fitur MFCC dan mel-spectrogram pada klasifikasi suara paru. *Jurnal RESTI (Rekayasa Sistem dan Teknologi Informasi)*, 6(4).
- Olah, C. (2015). Understanding LSTM networks. colah's blog. <https://colah.github.io/posts/2015-08-Understanding-LSTMs/>
- Park, D. S., Chan, W., Zhang, Y., Chiu, C.-C., Zoph, B., Cubuk, E. D., & Le, Q. V. (2019). SpecAugment: A simple data augmentation method for automatic speech recognition. *Interspeech 2019*, 2613-2617. <https://doi.org/10.21437/Interspeech.2019-2680>
- Pratama, R. S. A., & Amrullah, A. (2024). ANALYSIS OF WHISPER AUTOMATIC SPEECH RECOGNITION PERFORMANCE ON LOW

- RESOURCE LANGUAGE. *Jurnal Pilar Nusa Mandiri*, 20(1), 1–8.
<https://doi.org/10.33480/pilar.v20i1.4633>
- Prabhavalkar, R., Hori, T., Sainath, T. N., Schluter, R., & Watanabe, S. (2024). End-to-End Speech Recognition: A Survey. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 32, 325-351.
<https://doi.org/10.1109/TASLP.2023.3328283>
- Priadinata, I. P. B., Sudipa, I. G. I., Meinarni, N. P. S., Radhitya, I. M. L., & Supartha, I. K. D. G. (2025). Comparative analysis of LSTM, GRU, and Bi-LSTM deep learning models for Time Series Cryptocurrency price forecasting. *Sinkron*, 9(3), 1024–1035. <https://doi.org/10.33395/sinkron.v9i3.14795>
- Ramadhan, M. R., & Wibowo, A. (2024). Penerapan teknik data augmentation pada data audio untuk meningkatkan akurasi model deep learning. *Jurnal Media Informatika Budidarma*, 8(1).
- Roberts, L. (2020). Understanding the Mel Spectrogram. *Analytics Vidhya*.
<https://medium.com/analytics-vidhya/understanding-the-mel-spectrogram-fca2afa2ce53>
- Sari, I. P., & Putra, R. E. (2021). Implementasi recurrent neural network (RNN) dengan arsitektur bidirectional LSTM untuk analisis sekuensial. *Jurnal Teknik Informatika dan Sistem Informasi*, 8(3).
- Shewalkar, A., Nyavanandi, D., & Ludwig, S. A. (2019). Performance evaluation of deep neural networks applied to speech recognition: RNN, LSTM and GRU. *Journal of Artificial Intelligence and Soft Computing Research*, 9(4), 235-245. <https://doi.org/10.2478/jaiscr-2019-0006>
- Shiri, F. M., Perumal, T., Mustapha, N., & Mohamed, R. (2024). A Comprehensive Overview and Comparative Analysis on Deep Learning Models: CNN, RNN, LSTM, GRU. *Journal of Artificial Intelligence*, 6(1), 301-360.
<https://doi.org/10.32604/jai.2024.054314>
- Sudo, Y., Shakeel, M., Fukumoto, Y., Yan, B., Shi, J., Peng, Y., & Watanabe, S. (2024). Joint Beam Search Integrating CTC, Attention, and Transducer

Decoders. IEEE/ACM Transactions on Audio, Speech, and Language Processing. <https://doi.org/10.48550/arXiv.2406.02950>

Telmem, M., Laaidi, N., Ghanou, Y., Hamiane, S., & Satori, H. (2024). Comparative study of CNN, LSTM and hybrid CNN-LSTM model in Amazigh speech recognition using spectrogram feature extraction and different gender and age dataset. *International Journal of Speech Technology*, 27, 1121-1133. <https://doi.org/10.1007/s10772-024-10154-0>

Wang, Q., Feng, C., Xu, Y., Zhong, H., & Sheng, V. S. (2020). A novel privacy-preserving speech recognition framework using bidirectional LSTM. *Journal of Cloud Computing*, 9(1), 36. <https://doi.org/10.1186/s13677-020-00186-7>

Wijaya, K., & Santoso, H. (2023). Evaluasi kinerja model speech-to-text menggunakan metrik word error rate (WER) dan character error rate (CER). *Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer*, 7(2).